

History of NLP and Word Vectors

Nguyễn Duy Tân *

EE HCMUT ML&IoT Lab,
Trường Đại học Bách khoa Thành phố Hồ Chí Minh,
Đại học Quốc gia Thành phố Hồ Chí Minh
`tan.nguyen231305@hcmut.edu.vn`

Thành phố Hồ Chí Minh, Tháng 7 Năm 2026

Abstract

Quá trình phát triển của Xử lý Ngôn ngữ Tự nhiên (NLP) trải qua bốn kỷ nguyên chính, bắt đầu từ những nỗ lực cơ giới hóa dịch máy ban đầu cho đến sự thống trị của các hệ thống quy tắc thủ công thuộc Trí tuệ nhân tạo Ký hiệu (Symbolic AI). Khi các phương pháp dựa trên quy tắc bộc lộ giới hạn về khả năng mở rộng, lĩnh vực này đã chứng kiến sự chuyển dịch mô hình mạnh mẽ sang NLP thống kê xác suất và bước vào kỷ nguyên bùng nổ của Học sâu (Deep Learning) cùng các Mô hình Ngôn ngữ Lớn (LLMs). Đồng hành với sự thay đổi về hệ hình này là sự tiến hóa trong cách biểu diễn ý nghĩa từ vựng, từ bỏ các ký hiệu rời rạc thiếu liên kết ngữ nghĩa (như vector one-hot hay mạng lưới từ điển WordNet) để chuyển sang phương pháp Ngữ nghĩa Phân bố (Distributional Semantics). Thông qua các kiến trúc như Word2Vec (với Skip-gram, CBOW và Negative Sampling) hay GloVe, máy tính có thể học cách biểu diễn từ vựng dưới dạng các vector đặc liên tục (continuous dense vectors) bằng việc tối ưu hóa các hàm mục tiêu qua thuật toán giảm gradient (gradient descent). Phương pháp này cho phép hệ thống mô hình hóa chính xác các mối quan hệ loại suy và độ tương đồng ngữ nghĩa dựa trên bối cảnh xuất hiện của từ, từ đó đặt nền móng cốt lõi cho khả năng hiểu và tạo văn bản vượt trội của các tác nhân AI hiện đại.

1 Giới thiệu chung về Xử lý Ngôn ngữ Tự nhiên

Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP) là một lĩnh vực con của Trí tuệ nhân tạo (Artificial Intelligence – AI), đóng vai trò then chốt trong việc xây dựng các hệ thống máy tính có khả năng hiểu, diễn giải và sinh ra ngôn ngữ con người. Trong bối cảnh bùng nổ dữ liệu văn bản trên internet và sự xuất hiện của các mô hình ngôn ngữ lớn (Large Language Models – LLMs) như ChatGPT, Gemini hay Llama, NLP không chỉ là một chủ đề học thuật mà còn trở thành trụ cột công nghệ định hình cách chúng ta tương tác với thông tin và máy móc.

Tuy nhiên, để đạt được trình độ tinh vi như ngày nay, NLP đã trải qua một hành trình dài với những bước chuyển mình mang tính cách mạng. Việc thấu hiểu lịch sử phát triển của lĩnh vực này là điều kiện tiên quyết để nắm bắt bản chất của các kỹ thuật hiện đại. Lịch sử NLP không chỉ đơn thuần là một chuỗi các sự kiện hay phát minh; nó phản ánh cách mà các quan điểm triết học về ngôn ngữ và nhận thức đã dẫn dắt các nhà khoa học tạo ra những kiến trúc tính toán khác nhau.

1.1 Tổng quan và Khái niệm

Mục tiêu xuyên suốt của luận văn và các bài giảng trong khóa học *Natural Language Processing with Deep Learning* (CS224N) là giúp người học hiểu rõ các chuyển đổi mô hình (paradigm shifts) trong NLP, và cách mà những giả định cốt lõi về ngôn ngữ—liệu nó là một hệ thống ký hiệu logic hay một

*Bài viết được viết lại từ các slides [4, 5] và sử dụng AI như một công cụ hỗ trợ.

hiện tượng xác suất sinh ra từ ngữ cảnh—đã định hình những hướng tiếp cận khả thi trong mỗi thời kỳ lịch sử [?].

Xuyên suốt quá trình này, một thách thức cốt lõi luôn được đặt ra: **Làm thế nào để biểu diễn ý nghĩa của từ vựng một cách hữu dụng cho máy tính?** Từ những vector rời rạc (one-hot) thiếu khả năng liên kết ngữ nghĩa [4, p.8], đến các bộ từ điển hình thức (WordNet) đầy hạn chế về tính chủ quan và thiếu khả năng cập nhật [4, p.6], các nhà nghiên cứu nhận thấy cần một cách tiếp cận triệt để hơn.

1.2 Các kỹ thuật và Phương pháp cốt lõi

Bước đột phá thực sự đến từ việc áp dụng **Ngữ nghĩa Phân bố** (Distributional Semantics), dựa trên luận điểm kinh điển của J.R. Firth (1957): “You shall know a word by the company it keeps” [4, p.9]. Phương pháp này xây dựng các vector đặc, liên tục (dense vectors) cho từ vựng bằng cách phân tích bối cảnh xuất hiện của chúng trong một khoảng cửa sổ cố định.

Khóa học CS224N tập trung vào các phương pháp học sâu (Deep Learning) áp dụng cho NLP, bắt đầu từ các khái niệm cốt lõi như **Word2Vec** [1], **mạng nơ-ron hồi quy** (Recurrent Neural Networks – RNNs), **cơ chế chú ý** (Attention) và **kiến trúc Transformer** [3]. Những công cụ này tạo nền tảng cho các kỹ thuật tiên tiến đang thống trị năm 2025, bao gồm tiền huấn luyện (pretraining), hậu huấn luyện (post-training), tinh chỉnh hiệu quả (efficient adaptation), và xây dựng hệ thống tác nhân (agents) có khả năng suy luận (reasoning) và sử dụng công cụ [5, p.5].

1.3 Ứng dụng thực tiễn

Mục tiêu cuối cùng của việc học lý thuyết và các mô hình là để **xây dựng các hệ thống** giải quyết những bài toán lớn liên quan đến ngôn ngữ và điện toán. Điều này bao gồm việc biểu diễn từ ngữ (word representations), xây dựng hệ thống trả lời câu hỏi, tinh chỉnh LLMs, triển khai các pipeline Tăng cường sinh truy xuất (Retrieval-Augmented Generation – RAG), và phát triển các phương pháp đánh giá toàn diện cho các mô hình ngôn ngữ [5, p.5].

Phần còn lại của bài viết sẽ được tổ chức như sau. Phần 2 trình bày chi tiết bốn kỷ nguyên lịch sử của NLP, từ những nỗ lực dịch máy ban đầu cho đến sự bùng nổ của các Mô hình Ngôn ngữ Lớn. Phần 3 tập trung vào các phương pháp biểu diễn từ vựng, đi sâu vào kiến trúc Word2Vec, các kỹ thuật tối ưu như Negative Sampling, ma trận đồng xuất hiện (Co-occurrence) và mô hình GloVe. Cuối cùng, Phần 6 sẽ đề cập đến các phương pháp đánh giá mô hình, bao gồm đánh giá nội tại (intrinsic) và ngoại lai (extrinsic).

2 Các kỷ nguyên phát triển của Xử lý Ngôn ngữ Tự nhiên

Lịch sử của Xử lý Ngôn ngữ Tự nhiên (NLP) không chỉ là một chuỗi các phát minh công nghệ, mà còn phản ánh những cuộc tranh luận triết học sâu sắc về bản chất của ngôn ngữ và trí tuệ. Qua bốn kỷ nguyên phát triển, lĩnh vực này đã chứng kiến sự dịch chuyển từ những kỳ vọng viển vông, qua nỗ lực xây dựng các hệ thống quy tắc thủ công, đến việc áp dụng thống kê xác suất, và cuối cùng là sự bùng nổ của học sâu cùng các mô hình ngôn ngữ lớn [?]. Sự thay đổi này cho thấy cách các giả định về ngôn ngữ—coi nó như một hệ thống ký hiệu logic hay một hiện tượng thống kê sinh ra từ ngữ cảnh—đã định hình những gì khả thi về mặt tính toán trong mỗi thời đại.

2.1 Kỷ nguyên 1: Những khám phá ban đầu (1940–1969)

Nguồn gốc từ Dịch máy (Machine Translation). Nguồn gốc của NLP và Ngôn ngữ học Máy tính (Computational Linguistics) bắt nguồn từ những nỗ lực cơ giới hóa dịch thuật trong bối cảnh Chiến tranh Lạnh. Nhà toán học Warren Weaver, trong một lá thư năm 1947, đã đặt ra một ẩn dụ có sức ảnh hưởng lớn: khi nhìn vào một bài báo tiếng Nga, ông cho rằng "This is really written in English, but it has been coded in some strange symbols" và nhiệm vụ của máy tính là giải mã các ký hiệu đó [?, p.4]. Quan điểm này đã thúc đẩy làn sóng nghiên cứu dịch máy đầu tiên.

Những nền tảng song song. Đồng thời, những ý tưởng nền tảng cho trí tuệ nhân tạo và mạng nơ-ron cũng ra đời:

- Năm 1943, **Warren S. McCulloch và Walter Pitts** công bố mô hình toán học đầu tiên của mạng nơ-ron nhân tạo, chứng minh rằng nó có thể mô phỏng một cỗ máy Turing [?, p.12].
- Năm 1945, **Vannevar Bush** giới thiệu khái niệm "Memex" – một thiết bị cơ giới hóa lưu trữ và truy xuất thông tin cá nhân, đặt nền móng cho các hệ thống Truy xuất thông tin (Information Retrieval) sau này [?, p.17].
- Năm 1956, Hội nghị Dartmouth đánh dấu sự ra đời chính thức của AI, với hai trường phái đối lập: *Trí tuệ nhân tạo Ký hiệu* (Minsky, McCarthy, Simon, Newell) và *Điều khiển học* (Wiener, Rosenblatt) [?, p.16].

Sự lạc quan và sụp đổ ban đầu. Năm 1954, dự án hợp tác giữa IBM và Đại học Georgetown đã công bố trình diễn thành công "máy dịch điện tử" sử dụng máy tính IBM 701 với kho từ vựng 250 từ, gây chấn động dư luận [?, p.7]. Cùng năm đó, **Frank Rosenblatt** giới thiệu mô hình Perceptron (Mark I), mở ra hy vọng về một cỗ máy có thể "học thông qua hành động" [?, p.14].

Tuy nhiên, sự thiếu hiểu biết về cú pháp và ngữ nghĩa đã khiến những hệ thống này thất bại trước các câu phức tạp. **Báo cáo ALPAC** năm 1966 của Viện Hàn lâm Khoa học Quốc gia Hoa Kỳ đã chỉ trích gay gắt và cắt giảm tài trợ cho dịch máy, đưa lĩnh vực này vào thời kỳ "Mùa đông AI" đầu tiên [?, p.19].

2.2 Kỷ nguyên 2: Hệ thống NLP dựa trên ký hiệu thủ công (1970–1992)

Sự thống trị của Symbolic AI. Trong giai đoạn này, các nhà nghiên cứu từ bỏ tham vọng dịch máy tổng quát để tập trung vào xây dựng các hệ thống hiểu ngôn ngữ dựa trên quy tắc hình thức (formal rules) và biểu diễn tri thức. Các hệ thống tiêu biểu bao gồm **SHRDLU** của Terry Winograd (1972) – mô phỏng một thể giới khối xây dựng, và **LUNAR** của Woods (1973) – hỗ trợ truy vấn dữ liệu địa chất [?, p.25].

Các nhà nghiên cứu như Martin Kay, Fernando Pereira và Stuart Shieber đã phát triển các lý thuyết ngữ pháp hình thức và hợp nhất (Unification-based Grammars) để xây dựng cây cú pháp và biểu diễn ngữ nghĩa cho câu [?, p.26]. Luận án của **Peter Norvig** (1986) về *Unified Theory of Inference* là đỉnh cao của nỗ lực này, khi hệ thống cố gắng suy luận từ các cơ sở tri thức để hiểu các tham chiếu và sự kiện trong văn bản [?, p.29].

Giới hạn và sự chuyển mình. Các thuật toán ký hiệu tỏ ra không thể mở rộng (not scalable) do khối lượng tri thức và quy tắc khổng lồ. Symbolic AI một lần nữa đi vào ngõ cụt, gây ra "Mùa đông AI" lần thứ hai. Trong khi đó, các phương pháp xác suất đang lặng lẽ nảy mầm trong lĩnh vực nhận dạng giọng nói, đặc biệt là mô hình Kênh nhiễu (Noisy Channel) và Mô hình Markov ẩn (HMMs), mở đường cho cuộc cách mạng sắp tới [?, p.34].

2.3 Kỷ nguyên 3: NLP thống kê và Học máy có giám sát (1993–2012)

Hạ thấp kỳ vọng và tập trung vào tác vụ. Đây là giai đoạn các nhà nghiên cứu NLP "hạ thấp kỳ vọng" và từ bỏ tham vọng hiểu ngữ nghĩa hoàn chỉnh. Thay vào đó, họ tập trung giải quyết các bài toán con cụ thể bằng xác suất và thống kê, như: phân loại văn bản (text categorization), gán nhãn từ loại (Part-of-Speech tagging), nhận dạng thực thể (Named Entity Recognition), và phân tích cú pháp (parsing) [?, p.35].

Các cột mốc quan trọng. Frederick Jelinek và nhóm nghiên cứu tại IBM (1975) đã định nghĩa lại khái niệm *Mô hình Ngôn ngữ* (Language Model) như một phân phối xác suất để dự đoán token tiếp theo, ứng dụng cho sửa lỗi chính tả và nhận dạng giọng nói [?, p.51]. Sự bùng nổ của dữ liệu văn bản (như Penn Treebank) và sức mạnh tính toán (máy chủ lớn) đã thúc đẩy việc áp dụng các thuật toán học máy có giám sát như **Naïve Bayes**, **HMMs**, **PCFGs**, **CRFs** và **SVMs**. Đến những năm

2000, sự quan tâm bắt đầu chuyển dịch từ học có giám sát sang học không giám sát (ví dụ: Mô hình chủ đề LDA) và các ứng dụng ngữ nghĩa bậc cao hơn [?, p.37].

2.4 Kỷ nguyên 4: Học sâu và Mô hình Ngôn ngữ Lớn (2013–nay)

2.4.1 Kỷ nguyên Mạng nơ-ron (Neural NLP: 2013–2021)

Đột phá trong Nhận dạng giọng nói và Học sâu. Geoffrey Hinton và nhóm nghiên cứu tại Đại học Toronto (2009–2012) đã có những bước đột phá với mạng nơ-ron sâu (Deep Neural Networks). Các hệ thống này đã đạt được mức giảm tỷ lệ lỗi từ rất lớn trong nhận dạng giọng nói: từ 27.4% xuống 18.5% (giảm 33%) trên tập dữ liệu, và các hệ thống sau đó giảm tới 71–77% [?, p.42]. Điều này đã chứng minh sức mạnh vượt trội của mô hình nơ-ron so với phương pháp GMM truyền thống.

Cách mạng trong Biểu diễn từ và Dịch máy. Học sâu cung cấp một cách tiếp cận mới để biểu diễn ý nghĩa từ vựng thông qua các vector đặc (dense vectors) dựa trên **Ngữ nghĩa Phân bố** (Distributional Semantics) của Firth [?, p.44]. Các kiến trúc RNN và LSTM (ví dụ: mô hình Encoder-Decoder của Sutskever et al. 2014) đã cách mạng hóa Dịch máy (Machine Translation). Kết quả đánh giá BLEU trên tập Newstest2013 cho thấy Dịch máy Nơ-ron (NMT) đã vượt trội hoàn toàn so với Dịch máy Thống kê dựa trên cụm từ (SMT) từ năm 2014 đến 2016 [?, p.47]. Cơ chế Chú ý (Attention) ra đời như một giải pháp cho nút thắt cổ chai của LSTM, đặt nền móng cho các kiến trúc hiện đại sau này.

2.4.2 Kỷ nguyên Mô hình Ngôn ngữ Lớn (2022–nay)

Lịch sử hình thành Mô hình Ngôn ngữ. Ý tưởng về mô hình ngôn ngữ đã có từ rất sớm: Markov (1913) khám phá xác suất chuyển tiếp nguyên âm-phụ âm, Shannon (1948) phát triển lý thuyết thông tin và mô hình n-gram [?, p.51]. Tuy nhiên, kỷ nguyên LLM thực sự bắt đầu với sự bùng nổ về dữ liệu và tham số:

- **2000:** Bengio, Ducharme & Vincent giới thiệu mô hình ngôn ngữ nơ-ron đầu tiên trên 32 triệu token [?, p.52].
- **2007:** Brants et al. xây dựng mô hình n-gram trên 2 nghìn tỷ token, gọi là "Large Language Models" [?, p.52].
- **2018:** GPT và BERT xuất hiện, huấn luyện trên 3.3 tỷ token [?, p.52].
- **2020–nay:** Các mô hình với hơn 100 tỷ tham số (GPT-3/4, PaLM 2, Llama 3) huấn luyện trên hàng nghìn tỷ token trở thành tiêu chuẩn [?, p.53].

Tác động và Đánh giá. Sự ra mắt của ChatGPT đã làm cho việc đề cập đến AI trong các cuộc gọi báo cáo thu nhập của các công ty S&P 500 tăng vọt, chiếm tới 50% số công ty vào năm 2024 [?, p.49].

- **Hiệu suất công việc:** Các chuyên gia tư vấn tại Boston Consulting Group sử dụng GPT-4 hoàn thành nhiều tác vụ hơn 12.2%, nhanh hơn 25.1% và chất lượng cao hơn 40% so với nhóm không sử dụng. Hiệu quả đặc biệt rõ rệt với những người có kỹ năng thấp hơn [?, p.55].
- **Sáng tạo:** Dù mạnh về phân tích, các LLM vẫn kém xa con người trong sáng tác văn học. Nghiên cứu sử dụng Bài kiểm tra Sáng tạo Torrance (TTCW) chỉ ra rằng các câu chuyện do LLM tạo ra vượt qua ít bài kiểm tra hơn từ 3 đến 10 lần so với các tác phẩm của nhà văn chuyên nghiệp [?, p.56].

3 Biểu diễn Ý nghĩa của Từ vựng

Biểu diễn ý nghĩa của từ vựng là một trong những bài toán nền tảng nhất của Xử lý Ngôn ngữ Tự nhiên. Cách chúng ta mã hóa từ ngữ thành dữ liệu máy tính có thể xử lý sẽ định hình toàn bộ khả năng của các hệ thống sau này. Phần này trình bày sự tiến hóa từ các biểu diễn ký hiệu rời rạc (one-hot, WordNet) sang các vector đặc ngữ nghĩa dựa trên ngữ cảnh, tập trung vào mô hình Word2Vec, ma trận đồng xuất hiện, và kỹ thuật giảm chiều như SVD hay GloVe.

3.1 Hạn chế của biểu diễn Ký hiệu Rời rạc và Từ điển Hình thức

Trong các hệ thống NLP truyền thống, từ vựng được coi là các ký hiệu rời rạc (discrete symbols) và biểu diễn bằng vector one-hot. Với số chiều bằng kích thước từ điển (có thể lên tới 500.000+), mỗi từ được đánh dấu bằng một vị trí duy nhất trong vector. Ví dụ, *motel* và *hotel* được biểu diễn thành hai vector trực giao, dẫn đến tích vô hướng bằng 0—máy tính không thể phát hiện bất kỳ sự tương đồng ngữ nghĩa nào giữa chúng [4, p.8].

Một giải pháp khác là sử dụng các nguồn từ điển hình thức như **WordNet** (một cơ sở dữ liệu từ vựng chứa các bộ từ đồng nghĩa và quan hệ siêu danh từ). Mặc dù hữu ích, WordNet có nhiều nhược điểm:

- Thiếu sắc thái ngữ nghĩa (ví dụ: “proficient” chỉ là từ đồng nghĩa của “good” trong một số ngữ cảnh nhất định) [4, p.6].
- Không cập nhật kịp các nghĩa mới (từ lóng như “wicked”, “badass”, “ninja” trong các ngữ cảnh hiện đại).
- Phụ thuộc vào lao động thủ công, khó mở rộng và mang tính chủ quan.
- Không thể tính toán độ tương đồng giữa các từ một cách chính xác [4, p.6].

Do đó, nhu cầu về một cách biểu diễn từ vựng có thể học được từ dữ liệu và phản ánh được sự tương đồng ngữ nghĩa là cấp thiết.

3.2 Ngữ nghĩa Phân bố (Distributional Semantics)

Ngữ nghĩa phân bố là một trong những ý tưởng thành công nhất của NLP hiện đại [4, p.9]. Luận điểm của J. R. Firth (1957) “*You shall know a word by the company it keeps*” cho rằng ý nghĩa của một từ được xác định bởi các từ thường xuất hiện xung quanh nó. Cụ thể, với một văn bản, mỗi từ trung tâm w_t sẽ được bao quanh bởi một cửa sổ ngữ cảnh có kích thước cố định m . Các từ trong cửa sổ này (gọi là từ ngữ cảnh) tạo thành một phân phối ngữ cảnh đặc trưng cho từ đó.

Phương pháp này xây dựng một **vector đặc** (dense vector) cho mỗi từ sao cho các từ xuất hiện trong các ngữ cảnh tương tự sẽ có vector gần nhau trong không gian, và độ tương đồng được đo bằng tích vô hướng (dot product) hoặc cosine [4, p.10]. Đây là nền tảng cho các mô hình học vector từ như Word2Vec và GloVe.

3.3 Word2Vec: Khung học vector từ từ ngữ cảnh

Word2Vec, do Mikolov và cộng sự đề xuất năm 2013, là một khung học vector từ dựa trên mạng nơ-ron đơn giản, trong đó mỗi từ được biểu diễn bằng một vector và mô hình được tối ưu hóa để dự đoán xác suất xuất hiện của các từ ngữ cảnh cho một từ trung tâm cho trước (Skip-gram) hoặc ngược lại (CBOW) [4, p.11]. Dưới đây tập trung vào mô hình Skip-gram.

3.3.1 Hàm mục tiêu và Xác suất Softmax

Cho một ngữ liệu gồm T từ, với mỗi vị trí t , từ trung tâm w_t và cửa sổ ngữ cảnh kích thước m , hàm hợp lý được định nghĩa là xác suất dự đoán đúng tất cả các từ ngữ cảnh:

$$L(\theta) = \prod_{t=1}^T \prod_{-m \leq j \leq m, j \neq 0} P(w_{t+j} | w_t; \theta)$$

Hàm mục tiêu $J(\theta)$ là âm log hợp lý trung bình:

$$J(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{-m \leq j \leq m, j \neq 0} \log P(w_{t+j} | w_t; \theta)$$

Tối thiểu hóa $J(\theta)$ tương đương với tối đa hóa độ chính xác dự đoán [4, p.14].

Để tính xác suất, Word2Vec sử dụng hai vector cho mỗi từ w : v_w (vector khi là từ trung tâm) và u_w (vector khi là từ ngữ cảnh). Với từ trung tâm c và từ ngữ cảnh o , xác suất được tính bằng hàm softmax:

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

Hàm softmax biến các giá trị $u_w^T v_c$ thành một phân phối xác suất trên toàn bộ từ điển V , khuếch đại xác suất cho các từ có tích vô hướng lớn và vẫn phân bổ một phần xác suất cho các từ khác [4, p.17].

3.3.2 Tối ưu hóa bằng Gradient Descent và SGD

Các tham số θ bao gồm toàn bộ vector của tất cả các từ (cả v và u), với số chiều d và kích thước từ điển V , tổng cộng có $2dV$ tham số. Để tối thiểu hóa $J(\theta)$, thuật toán Gradient Descent lặp đi lặp lại cập nhật tham số theo hướng âm của gradient:

$$\theta^{\text{new}} = \theta^{\text{old}} - \alpha \nabla_{\theta} J(\theta)$$

với α là tốc độ học [4, p.21].

Tuy nhiên, $J(\theta)$ là hàm của tất cả các cửa sổ trong toàn bộ ngữ liệu (có thể hàng tỷ), nên việc tính gradient đầy đủ là rất đắt đỏ. **Stochastic Gradient Descent (SGD)** khắc phục bằng cách lấy mẫu ngẫu nhiên từng cửa sổ và cập nhật tham số ngay lập tức cho từng mẫu, giúp quá trình huấn luyện nhanh hơn nhiều và phù hợp với các mô hình nơ-ron [4, p.22].

3.3.3 Negative Sampling – Giảm độ phức tạp tính toán

Mẫu số của softmax yêu cầu tính tổng trên toàn bộ từ điển V (hàng triệu từ) cho mỗi cặp (trung tâm, ngữ cảnh), gây ra chi phí tính toán khổng lồ. Để giải quyết, phương pháp **Negative Sampling** (Mikolov et al. 2013) thay thế bài toán nhiều lớp bằng một tập hợp các bài toán phân loại nhị phân: huấn luyện mô hình phân biệt giữa cặp từ thực (xuất hiện cùng nhau trong ngữ cảnh) và k cặp từ "nhiều" (trung tâm ghép với từ ngẫu nhiên). Hàm mục tiêu mới là:

$$\sum_{(c,o) \in \text{real pairs}} \log \sigma(u_o^T v_c) + \sum_{k \text{ negative samples}} \log \sigma(-u_k^T v_c)$$

trong đó σ là hàm sigmoid. Các từ nhiễu được lấy mẫu dựa trên phân phối unigram lũy thừa 3/4 để tăng cường xác suất cho các từ ít phổ biến [4, p.27].

3.4 Phương pháp dựa trên Ma trận Đồng xuất hiện và GloVe

3.4.1 Ma trận đồng xuất hiện và SVD

Thay vì duyệt ngữ liệu nhiều lần, ta có thể thống kê trực tiếp số lần các từ xuất hiện cùng nhau trong một cửa sổ để tạo thành **ma trận đồng xuất hiện** X . Có hai loại:

- *Dựa trên cửa sổ*: Tương tự Word2Vec, nắm bắt thông tin cú pháp và ngữ nghĩa cục bộ [4, p.30].
- *Dựa trên tài liệu*: Phản ánh chủ đề tổng quát (ví dụ: các thuật ngữ thể thao có chung phân phối), gọi là Phân tích Ngữ nghĩa Tiềm ẩn (LSA).

Nhược điểm của ma trận này là kích thước rất lớn (số từ trong từ điển) và thưa thớt, gây khó khăn cho lưu trữ và phân loại. Để giảm chiều, người ta áp dụng **Phân tích Suy biến (Singular Value Decomposition – SVD)** trên X , giữ lại k giá trị suy biến lớn nhất để thu được các vector đặc với số chiều nhỏ (khoảng 25–1000). SVD cho phép tìm ma trận xấp xỉ hạng k tốt nhất theo nghĩa bình phương tối thiểu [4, p.33]. Tuy nhiên, việc áp dụng SVD trực tiếp trên ma trận đếm thô cho kết quả kém, cần các kỹ thuật tiền xử lý như lấy log tần suất, áp dụng ngưỡng, bỏ từ chức năng, dùng cửa sổ có trọng số, hoặc sử dụng tương quan thay vì đếm [4, p.34].

3.4.2 Mô hình GloVe: Kết hợp ưu điểm của đếm và học dựa trên ngữ cảnh

GloVe (Global Vectors for Word Representation) của Pennington, Socher và Manning (2014) là một mô hình lai khắc phục nhược điểm của cả SVD và Word2Vec. Thay vì học trực tiếp từ các cửa sổ, GloVe mã hóa *tỷ số xác suất đồng xuất hiện* thành các thành phần ý nghĩa tuyến tính trong không gian vector. Cụ thể, với mô hình log-bilinear:

$$w_i \cdot w_j = \log P(i|j)$$

Sự khác biệt vector của hai từ a và b có thể biểu diễn tỷ số xác suất:

$$w_x \cdot (w_a - w_b) = \log \frac{P(x|a)}{P(x|b)}$$

Hàm mất mát của GloVe:

$$J = \sum_{i,j=1}^V f(X_{ij}) \left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2$$

trong đó $f(X_{ij})$ là hàm trọng số để giảm ảnh hưởng của các cặp từ quá hiếm và quá phổ biến. GloVe có ưu điểm là huấn luyện nhanh và có thể mở rộng với ngữ liệu cực lớn, đạt kết quả vượt trội trong nhiều bài toán đánh giá [4, p.37].

Nhìn chung, các phương pháp học vector từ đều dựa trên nguyên lý ngữ nghĩa phân bố, khác biệt ở cách xây dựng hàm mục tiêu và chiến lược tối ưu. Word2Vec phù hợp với dữ liệu lớn nhờ SGD, SVD tận dụng được ma trận toàn cục, và GloVe dung hòa cả hai để đạt được kết quả tốt nhất trên nhiều tác vụ.

4 Word2Vec và Các phương pháp Tối ưu hóa

Word2Vec là một khung học biểu diễn từ vựng được giới thiệu bởi Mikolov và cộng sự vào năm 2013, đánh dấu bước ngoặt trong việc áp dụng học sâu vào NLP [1]. Khác với các phương pháp dựa trên ma trận đồng xuất hiện và SVD, Word2Vec học các vector từ bằng cách tối ưu hóa trực tiếp một hàm mục tiêu dựa trên xác suất ngữ cảnh, sử dụng kỹ thuật tối ưu ngẫu nhiên để xử lý ngữ liệu khổng lồ. Phần này trình bày chi tiết kiến trúc mô hình, hàm mục tiêu, các phương pháp tối ưu hóa và kỹ thuật lấy mẫu âm (negative sampling) giúp Word2Vec trở nên hiệu quả trong thực tế.

4.1 Kiến trúc Mô hình Word2Vec

Word2Vec có hai biến thể chính [4, p.25]:

1. **Skip-gram (SG)**: Dự đoán các từ ngữ cảnh (outside words) dựa trên một từ trung tâm (center word) cho trước. Mô hình này hoạt động tốt với các từ ít xuất hiện.
2. **Continuous Bag of Words (CBOW)**: Dự đoán từ trung tâm dựa trên một tập hợp (bag) các từ ngữ cảnh. CBOW thường nhanh hơn và cho kết quả tốt hơn cho các từ phổ biến.

Trong cả hai biến thể, mỗi từ w trong từ điển V được biểu diễn bằng *hai* vector: v_w (vector trung tâm) và u_w (vector ngữ cảnh). Việc sử dụng hai vector giúp việc tối ưu hóa dễ dàng hơn; sau khi huấn luyện, ta thường lấy trung bình hoặc tổng của hai vector làm biểu diễn cuối cùng [4, p.25].

4.2 Hàm mục tiêu và Xác suất Softmax

Xét một ngữ liệu gồm T từ. Với mỗi vị trí t , từ trung tâm w_t và cửa sổ ngữ cảnh kích thước m , mô hình Skip-gram tối đa hóa xác suất dự đoán đúng tất cả các từ ngữ cảnh. Hàm hợp lý của toàn bộ ngữ liệu là:

$$L(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w_{t+j} | w_t; \theta)$$

và hàm mục tiêu (loss) là âm log hợp lý trung bình [4, p.14]:

$$J(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

Xác suất có điều kiện $P(o | c)$ cho một từ ngữ cảnh o và từ trung tâm c được tính bằng hàm softmax trên tích vô hướng của hai vector tương ứng [4, p.15]:

$$P(o | c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}.$$

Hàm softmax ánh xạ các giá trị $u_w^T v_c$ thành một phân phối xác suất trên toàn bộ từ điển, đồng thời "khuếch đại" xác suất cho những từ có tích vô hướng lớn và vẫn dành một phần xác suất cho các từ có tích nhỏ hơn [4, p.17]. Mẫu số $\sum_{w \in V} \exp(u_w^T v_c)$ là nguyên nhân chính gây ra chi phí tính toán cao vì phải duyệt qua toàn bộ từ điển (có thể lên tới hàng triệu từ) cho mỗi cặp (trung tâm, ngữ cảnh).

4.3 Tối ưu hóa: Gradient Descent và Stochastic Gradient Descent

Mô hình Word2Vec được huấn luyện bằng cách tối thiểu hóa $J(\theta)$ theo các tham số θ , bao gồm tất cả các vector trung tâm và ngữ cảnh. Phương pháp Gradient Descent cập nhật tham số theo hướng âm của gradient:

$$\theta^{\text{new}} = \theta^{\text{old}} - \alpha \nabla_{\theta} J(\theta),$$

trong đó α là tốc độ học (learning rate) [4, p.21]. Với một ngữ liệu có hàng tỷ cửa sổ, việc tính gradient của toàn bộ $J(\theta)$ là quá đắt đỏ.

Để giải quyết, **Stochastic Gradient Descent (SGD)** được áp dụng: thay vì tính gradient trên toàn bộ dữ liệu, SGD lấy mẫu ngẫu nhiên một cửa sổ (hoặc một mini-batch) và cập nhật tham số ngay lập tức dựa trên gradient của cửa sổ đó [4, p.22]. Giải thuật SGD:

Algorithm 1 Stochastic Gradient Descent cho Word2Vec

- 1: **while** chưa hội tụ **do**
 - 2: Lấy ngẫu nhiên một vị trí t trong ngữ liệu
 - 3: Tính gradient $\nabla_{\theta} J_t(\theta)$ cho cửa sổ tại vị trí t
 - 4: $\theta \leftarrow \theta - \alpha \nabla_{\theta} J_t(\theta)$
 - 5: **end while**
-

SGD giúp quá trình huấn luyện nhanh hơn nhiều và có thể làm việc với các ngữ liệu không thể lưu trọn trong bộ nhớ. Ngoài ra, do chỉ ảnh hưởng đến các vector xuất hiện trong cửa sổ hiện tại, gradient của $J_t(\theta)$ rất thưa, cho phép tối ưu hóa cập nhật một cách hiệu quả khi số lượng từ vựng lớn [4, p.28].

4.4 Kỹ thuật Lấy mẫu âm (Negative Sampling)

Mặc dù SGD giảm được chi phí tính gradient trên toàn bộ dữ liệu, mỗi bước cập nhật vẫn phải tính mẫu số của softmax trên toàn bộ từ điển V . Để giải quyết vấn đề này, Mikolov et al. đề xuất **Negative Sampling (NEG)**, thay thế bài toán phân loại đa lớp bằng một tập các bài toán phân loại nhị phân [4, p.26].

Ý tưởng chính: Huấn luyện mô hình phân biệt giữa các cặp từ thực tế (xuất hiện cùng nhau trong cửa sổ) và các cặp từ "nhiều" (trung tâm ghép với một từ ngẫu nhiên). Với mỗi mẫu dương (cặp thực), ta lấy k mẫu âm. Hàm mục tiêu mới cho một cửa sổ là [4, p.27]:

$$J_t(\theta) = \log \sigma(u_o^T v_c) + \sum_{i=1}^k \mathbb{E}_{w_i \sim P_n(w)} [\log \sigma(-u_{w_i}^T v_c)],$$

trong đó $\sigma(x) = \frac{1}{1+\exp(-x)}$ là hàm sigmoid, và $P_n(w)$ là phân phối lấy mẫu âm. Thay vì tính softmax, mô hình chỉ cần tối ưu hóa các tích vô hướng của các cặp thực và nhiễu, giảm độ phức tạp từ $O(|V|)$ xuống $O(k)$.

Phân phối lấy mẫu $P_n(w)$ thường được chọn là *unigram distribution* lũy thừa 3/4 [4, p.27]:

$$P_n(w) = \frac{U(w)^{3/4}}{Z},$$

với $U(w)$ là tần suất của từ trong ngữ liệu và Z là hằng số chuẩn hóa. Phép lũy thừa 3/4 làm giảm xác suất của các từ quá phổ biến (như "the", "of") và tăng cường xác suất cho các từ ít phổ biến hơn, giúp mô hình học được các từ hiếm tốt hơn.

Nhờ Negative Sampling, Word2Vec có thể huấn luyện hiệu quả trên các ngữ liệu với hàng tỷ từ và từ điển triệu từ, trở thành công cụ nền tảng cho nhiều ứng dụng NLP sau này. Trong thực tế, giá trị k thường được chọn từ 5 đến 20 cho các ngữ liệu nhỏ, và từ 2 đến 5 cho các ngữ liệu lớn.

Tóm lại, Word2Vec kết hợp kiến trúc nơ-ron đơn giản (Skip-gram/CBOW), hàm mục tiêu dựa trên softmax, tối ưu ngẫu nhiên (SGD) và kỹ thuật lấy mẫu âm để học các vector từ chất lượng cao với chi phí tính toán hợp lý. Các vector này đã chứng minh khả năng nắm bắt các mối quan hệ ngữ nghĩa và cú pháp tinh vi, mở đường cho các mô hình ngôn ngữ sâu hơn sau này.

5 Ma trận Đồng xuất hiện và Mô hình GloVe

Trong khi Word2Vec học vector từ bằng cách duyệt qua ngữ liệu nhiều lần và cập nhật tham số dựa trên từng cửa sổ ngữ cảnh, một hướng tiếp cận khác đặt ra câu hỏi: tại sao không thống kê trực tiếp tất cả các lần xuất hiện của các từ cạnh nhau để xây dựng một ma trận toàn cục? Phương pháp này dẫn đến ma trận đồng xuất hiện (co-occurrence matrix) và các kỹ thuật giảm chiều như SVD. Tuy nhiên, các phương pháp đếm trực tiếp này có những hạn chế riêng, dẫn đến sự ra đời của GloVe (Global Vectors for Word Representation) – một mô hình kết hợp ưu điểm của cả hai cách tiếp cận: học dựa trên ngữ cảnh và thống kê toàn cục [2].

5.1 Ma trận Đồng xuất hiện (Co-occurrence Matrix)

Thay vì học tham số qua nhiều epoch, ta có thể xây dựng một ma trận X trong đó mỗi hàng và cột tương ứng với một từ trong từ điển, và X_{ij} là số lần từ i xuất hiện trong ngữ cảnh của từ j [4, p.30]. Có hai cách xây dựng ma trận này:

- **Dựa trên cửa sổ (window-based):** Tương tự như Word2Vec, ta xác định một cửa sổ có kích thước cố định xung quanh mỗi từ và đếm số lần các từ xuất hiện cùng nhau trong cửa sổ đó. Ma trận này nắm bắt thông tin cú pháp và ngữ nghĩa cục bộ, tạo ra "không gian từ" (word space). Ví dụ, với ngữ liệu nhỏ gồm ba câu: "I like deep learning", "I like NLP", "I enjoy flying" và cửa sổ kích thước 1, ta thu được ma trận đồng xuất hiện đối xứng như sau [4, p.31]:

	I	like	enjoy	deep	learning	NLP	flying
I	0	2	1	0	0	0	0
like	2	0	0	1	0	1	0
enjoy	1	0	0	0	0	0	1
deep	0	1	0	0	1	0	0
learning	0	0	0	1	0	0	0
NLP	0	1	0	0	0	0	0
flying	0	0	1	0	0	0	0

- **Dựa trên toàn bộ tài liệu (document-based):** Đếm số lần hai từ xuất hiện trong cùng một văn bản. Phương pháp này phản ánh chủ đề tổng quát (ví dụ, các thuật ngữ thể thao sẽ có vector tương tự nhau), dẫn đến Phân tích Ngữ nghĩa Tiềm ẩn (Latent Semantic Analysis – LSA) hay "không gian tài liệu" (document space) [4, p.30].

Nhược điểm của ma trận đồng xuất hiện. Mặc dù đơn giản và tận dụng được thông tin toàn cục, ma trận đồng xuất hiện có các hạn chế nghiêm trọng:

- **Kích thước lớn:** Số chiều bằng kích thước từ điển $|V|$ (có thể hàng trăm nghìn), gây tốn bộ nhớ.
- **Ma trận thưa (sparse):** Hầu hết các cặp từ không xuất hiện cùng nhau, dẫn đến nhiều giá trị 0, gây khó khăn cho các mô hình học máy sau này.
- **Độ mạnh mẽ (robustness) kém:** Các bộ phân loại trên không gian thưa thường kém ổn định và dễ bị quá khớp [4, p.32].

5.2 Giảm chiều dữ liệu bằng SVD

Để khắc phục, người ta áp dụng kỹ thuật **Phân tích Suy biến (Singular Value Decomposition – SVD)** để giảm số chiều của ma trận đồng xuất hiện, giữ lại k giá trị suy biến lớn nhất để tạo thành các vector đặc có số chiều nhỏ (thường 25–1000) [4, p.33]. SVD phân tích ma trận X thành $U\Sigma V^T$, trong đó U và V là các ma trận trực chuẩn (orthonormal), và Σ là ma trận đường chéo chứa các giá trị suy biến. Giữ lại k giá trị suy biến lớn nhất cho ta ma trận $\hat{X}$ là xấp xỉ hạng k tốt nhất của X theo nghĩa bình phương tối thiểu [4, p.33].

Tuy nhiên, áp dụng SVD trực tiếp trên ma trận đếm thô thường cho kết quả kém, vì các từ chức năng (function words) như "the", "he", "has" xuất hiện quá thường xuyên và làm nhiễu thông tin ngữ nghĩa. Các kỹ thuật tinh chỉnh cần được áp dụng [4, p.34]:

- Lấy log tần suất: $\log(X_{ij})$ hoặc $\min(X_{ij}, t)$ với $t \approx 100$.
- Bỏ qua các từ chức năng.
- Sử dụng cửa sổ có trọng số (ramped windows): các từ gần trung tâm được đếm nhiều hơn.
- Sử dụng tương quan thay vì số đếm, sau đó đặt các giá trị âm về 0.

Các thủ thuật này giúp làm nổi bật các mối quan hệ ngữ nghĩa, như minh họa trong mô hình COALS (Rohde et al., 2005), nơi các mối quan hệ loại suy như "man:woman :: king:queen" hiện lên rõ ràng trong không gian vector được chuẩn hóa [4, p.35].

5.3 Mô hình GloVe: Kết hợp đếm toàn cục và học dựa trên ngữ cảnh

GloVe (Global Vectors for Word Representation) do Pennington, Socher và Manning đề xuất năm 2014 [2] là một mô hình dung hòa giữa các phương pháp dựa trên ma trận (như SVD) và các phương pháp học dựa trên cửa sổ (như Word2Vec). Ý tưởng cốt lõi: thay vì học trực tiếp từ xác suất đồng xuất hiện, GloVe mã hóa *tỷ số của các xác suất đồng xuất hiện* thành các thành phần ý nghĩa tuyến tính trong không gian vector.

5.3.1 Cơ sở lý thuyết: Tỷ số xác suất đồng xuất hiện

Xét ba từ a , b , và x . GloVe nhận thấy rằng tỷ số $\frac{P(x|a)}{P(x|b)}$ chứa nhiều thông tin ngữ nghĩa hơn là bản thân các xác suất riêng lẻ. Ví dụ, với $a = \text{"ice"}$, $b = \text{"steam"}$, và x lần lượt là "solid", "gas", "water", "fashion", các tỷ số này phản ánh mối quan hệ giữa các từ một cách tinh tế [4, p.36]. Mô hình log-bilinear cho phép biểu diễn tỷ số này dưới dạng hiệu của các vector:

$$w_x \cdot (w_a - w_b) = \log \frac{P(x|a)}{P(x|b)}.$$

Điều này có nghĩa là sự khác biệt giữa vector của hai từ a và b sẽ mã hóa các thành phần ý nghĩa liên quan đến ngữ cảnh x .

5.3.2 Hàm mục tiêu của GloVe

Từ quan hệ trên, GloVe định nghĩa hàm mất mát (loss function) trên toàn bộ ma trận đồng xuất hiện X [4, p.37]:

$$J = \sum_{i,j=1}^V f(X_{ij}) \left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2,$$

trong đó:

- V là kích thước từ điển.
- w_i và $\tilde{w}_j$ lần lượt là vector trung tâm và vector ngữ cảnh của từ (tương tự Word2Vec).
- b_i và $\tilde{b}_j$ là các bias để tăng tính linh hoạt.
- X_{ij} là số lần từ i và j xuất hiện cùng nhau.
- $f(X_{ij})$ là hàm trọng số để kiểm soát ảnh hưởng của các cặp từ quá hiếm (giảm nhiều) và quá phổ biến (tránh trội quá mức).

Ưu điểm của GloVe. So với SVD, GloVe không cần xây dựng lại toàn bộ ma trận và có thể huấn luyện trực tiếp trên các cặp khác 0 của X , giúp tiết kiệm bộ nhớ và thời gian. So với Word2Vec, GloVe tận dụng được thông tin thống kê toàn cục, giúp học được các vector ổn định hơn và đạt kết quả tốt hơn trên nhiều tác vụ đánh giá [4, p.37]. GloVe có thể huấn luyện nhanh chóng trên các ngữ liệu cực lớn và thường được sử dụng trong các hệ thống NLP hiện đại.

5.4 So sánh các phương pháp

Bảng dưới đây tóm tắt sự khác biệt giữa ba phương pháp học vector từ:

Tiêu chí	SVD	Word2Vec	GloVe
Cách tiếp cận	Thống kê toàn cục	Học dựa trên cửa sổ	Kết hợp toàn cục và cửa sổ
Hàm mục tiêu	Xấp xỉ ma trận X	Softmax/Sigmoid (SGD)	Hồi quy trên $\log X_{ij}$
Thông tin sử dụng	Toàn bộ ma trận	Từng cửa sổ	Toàn bộ ma trận
Khả năng mở rộng	Kém ($O(V ^3)$)	Tốt ($O(V)$)	Tốt ($O(V ^2)$ thưa)
Chất lượng vector	Trung bình (cần tinh chỉnh)	Tốt	Rất tốt (trên nhiều tác vụ)

Tóm lại, ma trận đồng xuất hiện cung cấp một cách tiếp cận trực quan để nắm bắt thông tin ngữ nghĩa, nhưng gặp khó khăn về kích thước và tính thưa thớt. SVD giúp giảm chiều nhưng đòi hỏi nhiều kỹ thuật tiền xử lý. GloVe khắc phục các nhược điểm này bằng cách kết hợp thống kê toàn cục với tối ưu hóa hiệu quả, tạo ra các vector từ vừa chính xác vừa có khả năng mở rộng cao.

6 Đánh giá Mô hình Ngôn ngữ và Vector Từ

Sau khi đã xây dựng các biểu diễn từ vệt và mô hình ngôn ngữ, một câu hỏi quan trọng được đặt ra: làm thế nào để đánh giá chất lượng của chúng? Phần này trình bày các phương pháp đánh giá vector từ và mô hình ngôn ngữ, phân biệt giữa đánh giá nội tại (intrinsic) và ngoại lai (extrinsic), đồng thời đề cập đến các thử nghiệm đánh giá khả năng sáng tạo của các mô hình ngôn ngữ lớn (LLMs). Các phương pháp này không chỉ giúp so sánh các mô hình khác nhau mà còn cung cấp cái nhìn sâu sắc về điểm mạnh và điểm yếu của từng cách biểu diễn.

6.1 Phân loại đánh giá: Intrinsic vs. Extrinsic

Việc đánh giá trong NLP thường được chia thành hai loại [4, p.38]:

- **Đánh giá nội tại (Intrinsic):** Đánh giá trên một tác vụ phụ trung gian, cụ thể và được thiết kế riêng. Các ưu điểm bao gồm tốc độ tính toán nhanh, giúp hiểu rõ hơn về hệ thống. Tuy nhiên, nhược điểm là không rõ liệu hiệu suất tốt trên tác vụ nội tại có tương quan với hiệu suất trên các ứng dụng thực tế hay không.
- **Đánh giá ngoại lai (Extrinsic):** Đánh giá trên một tác vụ thực tế (ví dụ: nhận dạng thực thể, trả lời câu hỏi). Ưu điểm là phản ánh trực tiếp hiệu quả sử dụng trong thực tế. Nhược điểm là thời gian tính toán lâu, và khó xác định nguyên nhân thành công hay thất bại (do lỗi từ mô-đun con hay do tương tác giữa các mô-đun) [4, p.38].

Trong phần này, chúng ta tập trung vào các phương pháp đánh giá nội tại phổ biến cho vector từ, sau đó đề cập đến một ví dụ đánh giá ngoại lai, và cuối cùng mở rộng sang đánh giá khả năng sáng tạo của LLMs.

6.2 Đánh giá nội tại vector từ

6.2.1 Phép loại suy (Word Vector Analogies)

Một cách đánh giá nội tại kinh điển là sử dụng các phép loại suy (analogies) như "man:woman :: king:queen". Ý tưởng là các vector từ thu được cần phải thỏa mãn mối quan hệ cộng-vector: vector của từ đích d (queen) phải gần với vector $v_{\text{king}} - v_{\text{man}} + v_{\text{woman}}$ nhất trong không gian vector, và khoảng cách được đo bằng cosine similarity [4, p.39]. Cụ thể:

$$d = \arg \max_{w \notin \{\text{king, man, woman}\}} \text{cosine}(v_w, v_{\text{king}} - v_{\text{man}} + v_{\text{woman}}).$$

Các tập dữ liệu đánh giá loại suy thường bao gồm cả quan hệ ngữ nghĩa (ví dụ: thành phố-thủ đô) và quan hệ cú pháp (ví dụ: so sánh hơn-so sánh nhất). Mặc dù phương pháp này nhanh và trực quan, nó có hạn chế: giả định các mối quan hệ ngữ nghĩa là tuyến tính, và có thể bỏ qua các mối quan hệ phi tuyến tính trong dữ liệu [4, p.39].

6.2.2 Độ tương đồng ngữ nghĩa (Semantic Similarity)

Một phương pháp đánh giá nội tại khác là đo độ tương đồng giữa các vector từ và so sánh với đánh giá của con người. Các tập dữ liệu như **WordSim353** [4, p.41] cung cấp các cặp từ cùng với điểm số tương đồng trung bình do con người đánh giá (ví dụ: tiger-cat đạt 7.35, stock-jaguar chỉ 0.92). Đánh giá một mô hình bằng cách tính hệ số tương quan Spearman giữa độ tương đồng cosine của các vector từ và điểm số của con người. Bảng kết quả từ nhiều mô hình khác nhau (SVD, CBOW, Skip-gram, GloVe) cho thấy các mô hình học sâu và GloVe thường đạt tương quan cao hơn trên nhiều tập dữ liệu như WS353, MC, RG, CWS, và RW [4, p.42]. Ví dụ, GloVe trên 42B token đạt 75.9 trên WS353, cao hơn đáng kể so với SVD thô (35.3) và các mô hình CBOW/SG.

6.3 Đánh giá ngoại lai vector từ: Nhận dạng thực thể có tên (NER)

Để kiểm tra tính hữu dụng của vector từ trong tác vụ thực tế, người ta có thể thay thế các biểu diễn đầu vào (one-hot, SVD, Word2Vec, GloVe, v.v.) trong một hệ thống cụ thể, ví dụ như bài toán **Nhận dạng thực thể có tên** (Named Entity Recognition – NER) trên các bộ dữ liệu ACE và MUC7 [4, p.43]. Kết quả cho thấy:

- Các biểu diễn học từ ngữ cảnh (như GloVe, CBOW) cho độ chính xác cao hơn so với các biểu diễn thưa thớt (discrete) hoặc SVD không tinh chỉnh.
- GloVe đạt 93.2% trên tập phát triển (Dev) và 88.3% trên tập kiểm tra (Test) của ACE, vượt trội so với các mô hình khác, chứng tỏ giá trị của việc kết hợp thông kê toàn cục và học dựa trên ngữ cảnh.

Đánh giá ngoại lai như vậy cho thấy rõ ràng sự cải thiện khi chọn lựa biểu diễn từ phù hợp, nhưng cũng đòi hỏi nhiều thời gian và tài nguyên tính toán để chạy toàn bộ pipeline.

6.4 Đánh giá sáng tạo của Mô hình Ngôn ngữ Lớn

Với sự phát triển của các LLM như GPT-4, nhu cầu đánh giá khả năng sáng tạo và chất lượng văn bản sinh ra ngày càng được quan tâm. Một hướng tiếp cận là áp dụng **Bài kiểm tra Sáng tạo Torrance (Torrance Test of Creative Writing – TTCW)** dựa trên Kỹ thuật Đánh giá Đồng thuận (Consensual Assessment Technique) [?, p.56]. TTCW gồm 14 tiêu chí nhị phân thuộc bốn khía cạnh: Trôi chảy (Fluency), Linh hoạt (Flexibility), Độc đáo (Originality), và Phát triển (Elaboration).

Trong một nghiên cứu gần đây [?, p.56], 10 nhà văn chuyên nghiệp đã đánh giá 48 câu chuyện được viết bởi các tác giả chuyên nghiệp và bởi các LLM. Kết quả cho thấy:

- Các câu chuyện do LLM tạo ra vượt qua ít bài kiểm tra hơn từ 3 đến 10 lần so với các câu chuyện của nhà văn chuyên nghiệp.
- Khi sử dụng chính các LLM để tự động hóa đánh giá TTCW, không có LLM nào có tương quan tích cực với đánh giá của chuyên gia.

Điều này cho thấy dù LLMs có khả năng tạo văn bản mượt mà, chúng vẫn còn khoảng cách lớn so với sự sáng tạo và tinh tế của con người, ít nhất là ở thời điểm năm 2023.

Tuy nhiên, các LLM lại tỏ ra vượt trội trong các tác vụ phân tích và hỗ trợ công việc. Một nghiên cứu của Boston Consulting Group cho thấy các chuyên gia tư vấn sử dụng GPT-4 hoàn thành nhiều tác vụ hơn 12.2%, nhanh hơn 25.1% và chất lượng cao hơn 40% so với nhóm không sử dụng, đặc biệt cải thiện mạnh đối với nhóm có kỹ năng thấp hơn [?, p.55]. Điều này cho thấy LLMs là công cụ hỗ trợ đắc lực, ngay cả khi chưa thể thay thế hoàn toàn sự sáng tạo của con người.

Tóm lại, việc đánh giá vector từ và mô hình ngôn ngữ đòi hỏi sự kết hợp giữa các phương pháp nội tại (analogies, similarity) và ngoại lai (NER, các tác vụ đầu cuối). Đối với các LLM hiện đại, cần bổ sung các thước đo về sáng tạo và sự tương tác với con người để có cái nhìn toàn diện về khả năng và giới hạn của chúng.

7 Tổng kết

Hành trình phát triển của Xử lý Ngôn ngữ Tự nhiên (NLP) trong hơn bảy thập kỷ qua cho thấy một sự chuyển mình sâu sắc về mặt triết học và kỹ thuật. Từ những ngày đầu đầy lạc quan nhưng non nớt của dịch máy dựa trên mặt mã học, qua nỗ lực xây dựng các hệ thống quy tắc thủ công mô phỏng tri thức và suy luận của con người, đến cuộc cách mạng thống kê xác suất và bùng nổ của học sâu cùng các mô hình ngôn ngữ lớn, NLP đã liên tục thích nghi để giải quyết những thách thức phức tạp của ngôn ngữ tự nhiên. Mỗi kỷ nguyên đều mang đến những đóng góp giá trị, nhưng cũng bộc lộ những giới hạn riêng, từ khả năng mở rộng kém của các hệ thống ký hiệu cho đến chi phí tính toán khổng lồ của softmax trong Word2Vec.

Trọng tâm xuyên suốt của các phương pháp hiện đại là cách biểu diễn ý nghĩa từ vựng – một bài toán nền tảng quyết định mọi khả năng của hệ thống. Sự thất bại của biểu diễn một-hot và từ điển hình thức như WordNet trong việc nắm bắt các mối quan hệ tinh tế giữa các từ đã dẫn đến sự ra đời của các vector đặc dựa trên Ngữ nghĩa Phân bố (Distributional Semantics). Word2Vec đã khởi xướng xu hướng học vector từ bằng cách tối ưu hóa trực tiếp xác suất ngữ cảnh thông qua các kỹ thuật như Negative Sampling và Stochastic Gradient Descent, cho phép huấn luyện trên ngữ liệu khổng lồ. Trong khi đó, GloVe kết hợp hài hòa thống kê toàn cục của ma trận đồng xuất hiện với khả năng tối ưu hiệu quả, tạo ra các vector từ có chất lượng cao trên nhiều tác vụ đánh giá [2].

Việc đánh giá các mô hình và vector từ cũng trở nên đa dạng, từ các phép loại suy và độ tương đồng ngữ nghĩa (đánh giá nội tại) đến các tác vụ thực tế như nhận dạng thực thể (đánh giá ngoại lai). Các phương pháp này không chỉ giúp so sánh mà còn làm sáng tỏ điểm mạnh và điểm yếu của từng cách tiếp cận.

Ngày nay, sự phát triển của các mô hình ngôn ngữ lớn (LLMs) như GPT-4, PaLM 2 hay Llama 3 đã mở ra một kỷ nguyên mới, nơi các mô hình có hàng trăm tỷ tham số huấn luyện trên hàng nghìn tỷ token có thể thực hiện nhiều tác vụ ngôn ngữ ở mức độ ấn tượng. Chúng không chỉ vượt trội trong

các bài toán phân tích và hỗ trợ công việc (cải thiện hiệu suất lên tới 40%) [?, p.55], mà còn đặt ra những thách thức mới về đánh giá sáng tạo, tính công bằng và độ tin cậy. Mặc dù còn khoảng cách lớn so với khả năng sáng tác văn học của con người [?, p.56], các LLM đã chứng minh tiềm năng to lớn như những trợ lý đắc lực, đồng thời thúc đẩy nghiên cứu về các phương pháp tinh chỉnh hiệu quả, suy luận và hợp tác giữa người và máy.

Tóm lại, lịch sử NLP là câu chuyện về sự tiến hóa của các giả định và công cụ: từ ký hiệu tĩnh sang xác suất động, từ quy tắc thủ công sang học tự động, và từ các mô hình chuyên biệt sang các nền tảng đa năng. Để tiếp tục tiến bộ, cần không ngừng đặt lại câu hỏi về cách biểu diễn tri thức, cách đánh giá toàn diện, và cách xây dựng các hệ thống vừa mạnh mẽ vừa có thể giải thích được. Sự kết hợp giữa các phương pháp thống kê, học sâu và tri thức nhân văn sẽ là chìa khóa để NLP vượt qua các thách thức hiện tại và tiến tới sự hiểu biết thực sự về ngôn ngữ con người.

References

- [1] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.
- [2] Jeffrey Pennington, Richard Socher, and Christopher D. Manning. Glove: Global vectors for word representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1532–1543, 2014.
- [3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5998–6008, 2017.
- [4] Diyi Yang. Natural language processing with deep learning: Lecture 2 – word vectors. Stanford University CS224N / Ling284, 2026. Slide PDF.
- [5] Diyi Yang and Yejin Choi. Natural language processing with deep learning: Lecture 1 – introduction and the history of nlp. Stanford University CS224N / Ling284, 2026. Slide PDF.