

Pretraining

Nguyễn Duy Tân *

EE HCMUT ML&IoT Lab,
Trường Đại học Bách khoa Thành phố Hồ Chí Minh,
Đại học Quốc gia Thành phố Hồ Chí Minh
`tan.nguyen231305@hcmut.edu.vn`

Thành phố Hồ Chí Minh, Tháng 7 Năm 2026

Abstract

Bài viết tập trung trình bày về tiền huấn luyện (pretraining), một phương pháp cốt lõi đã tạo ra bước đột phá và nâng cao đáng kể hiệu suất của các hệ thống Xử lý Ngôn ngữ Tự nhiên (NLP) thông qua việc học không giám sát trên quy mô dữ liệu khổng lồ. Nội dung bắt đầu với phương pháp mô hình hóa từ vựng phụ (subword modeling) tiêu biểu là thuật toán Byte-pair encoding giúp xử lý linh hoạt các từ hiếm, từ mới hoặc từ viết sai chính tả. Tiếp đó, bài viết phân tích chi tiết ba cách tiếp cận tiền huấn luyện tương ứng với ba loại kiến trúc mạng nơ-ron: (1) Bộ giải mã (Decoders) như GPT sử dụng mô hình hóa ngôn ngữ truyền thống để sinh văn bản; (2) Bộ mã hóa (Encoders) như BERT và các biến thể tận dụng ngữ cảnh hai chiều để dự đoán các từ bị che khuất (Masked Language Modeling); và (3) Kiến trúc kết hợp Bộ mã hóa - Giải mã (Encoder-Decoders) như T5 sử dụng mục tiêu khôi phục các đoạn văn bản bị biến đổi (span corruption). Thông qua quá trình khôi phục đầu vào này, mô hình học được đa dạng các thuộc tính của ngôn ngữ bao gồm cú pháp, ngữ nghĩa, cảm xúc và kiến thức thực tế, dù đôi khi có thể hấp thụ cả những định kiến xấu và vướng phải các vấn đề về bản quyền. Cuối cùng, bài viết đề cập đến các định luật mở rộng (scaling laws) chứng minh rằng hiệu suất mô hình có thể dự đoán và gia tăng dựa trên quy mô tính toán, đồng thời giới thiệu khả năng "học trong ngữ cảnh" (in-context learning) vô cùng mạnh mẽ của các mô hình ngôn ngữ cực lớn như GPT-3, cho phép chúng thực hiện tác vụ mới chỉ thông qua các ví dụ ở đầu vào mà không cần tinh chỉnh lại trọng số.

Contents

1	Động lực của Pretraining	3
2	Mô hình hóa Subword	4
2.1	Vấn đề của Từ vựng Cố định	4
2.2	Thuật toán Byte-Pair Encoding (BPE)	4
2.3	Các Thuật toán Subword Phổ biến khác	4
2.4	Thách thức khi áp dụng Subword cho Các Tác vụ Gán nhãn	5
3	Ba cách tiếp cận Pretraining Mô hình	5
3.1	Bộ mã hóa (Encoders) – Học biểu diễn hai chiều	5
3.1.1	Đặc điểm và Mục tiêu Tiền huấn luyện	5
3.1.2	Các mô hình và Biến thể	6
3.1.3	Tinh chỉnh (Fine-tuning)	6
3.2	Bộ giải mã (Decoders) – Mô hình ngôn ngữ tự hồi quy	6

*Bài viết được viết lại từ các slides [7] và sử dụng AI như một công cụ hỗ trợ.

3.2.1	Đặc điểm và Mục tiêu Tiền huấn luyện	6
3.2.2	Các mô hình tiêu biểu	6
3.2.3	Tinh chỉnh và Sử dụng	6
3.3	Kiến trúc Mã hóa-Giải mã (Encoder-Decoders)	7
3.3.1	Đặc điểm và Mục tiêu Tiền huấn luyện	7
3.3.2	Ứng dụng và Đánh giá	7
3.4	Tổng kết So sánh	7
4	Khám phá sự thật: Pretraining đang <i>dạy</i> mô hình điều gì?	7
4.1	Những Kiến thức Ngôn ngữ và Thế giới được Học	8
4.2	Định kiến Xã hội và Rủi ro An toàn	8
4.3	Vấn đề Bản quyền và Quyền riêng tư	9
5	Mô hình quy mô cực lớn và Học trong ngữ cảnh	9
5.1	Định luật Mở rộng (Scaling Laws)	9
5.2	Hiệu suất Mở rộng và Chiến lược Tối ưu	10
5.3	Học trong Ngữ cảnh (In-context Learning)	10
6	Tổng kết	10

1 Động lực của Pretraining

Sự phát triển của các mô hình ngôn ngữ lớn trong những năm gần đây đã định hình lại hoàn toàn bộ mặt của Xử lý Ngôn ngữ Tự nhiên. Mấu chốt của cuộc cách mạng này là một kỹ thuật mang tên **tiền huấn luyện (pretraining)** [7]. Thay vì xây dựng các mô hình từ đầu cho từng tác vụ cụ thể, pretraining cho phép chúng ta huấn luyện một mô hình tổng quát trên một lượng dữ liệu khổng lồ không cần gán nhãn, sau đó tinh chỉnh nó cho các bài toán riêng biệt. Phần này sẽ đi sâu vào động lực đằng sau sự thay đổi mang tính bước ngoặt này, bắt đầu từ những hạn chế của các phương pháp biểu diễn từ truyền thống, dẫn đến sự ra đời của các mô hình nền tảng (foundation models) mạnh mẽ như BERT và Llama 3.

Từ Word Embeddings tĩnh đến Mô hình Nền tảng. Trước khi pretraining trở thành xu hướng chủ đạo, các hệ thống NLP hoạt động dựa trên một giả định đơn giản hóa: mỗi từ (word type) được biểu diễn bằng một vector cố định, không phụ thuộc vào ngữ cảnh mà nó xuất hiện [7]. Các kỹ thuật như Word2Vec [?] hay GloVe [?] đã thành công trong việc tạo ra các biểu diễn từ giàu ý nghĩa, nhưng chúng vấp phải một hạn chế cố hữu: từ "record" trong hai câu "I *record* the music" và "I play the *record*" sẽ có cùng một vector, mặc dù nghĩa của chúng hoàn toàn khác nhau (động từ ghi âm và danh từ đĩa hát) [7].

Khoảng năm 2017, một cách tiếp cận phổ biến là khởi tạo các từ với các vector tĩnh (pretrained word embeddings), sau đó đưa chúng vào các mô hình phức tạp hơn như LSTM hoặc Transformer để học cách kết hợp ngữ cảnh trong quá trình huấn luyện cho tác vụ cụ thể. Tuy nhiên, phương pháp này có hai vấn đề lớn [7]:

1. Dữ liệu gán nhãn cho tác vụ hạ nguồn (như trả lời câu hỏi) phải đủ lớn để mô hình học được mọi khía cạnh về ngữ cảnh của ngôn ngữ, điều này thường không khả thi.
2. Phần lớn các tham số của mô hình (không phải word embeddings) vẫn được khởi tạo ngẫu nhiên, dẫn đến việc huấn luyện kém hiệu quả và tốn kém.

Bước đột phá đến từ việc khởi tạo *toàn bộ* các tham số của mô hình thông qua pretraining [7]. Ý tưởng cốt lõi là sử dụng các phương pháp học tự giám sát (self-supervised learning) trên dữ liệu văn bản khổng lồ từ Internet: che giấu một phần của đầu vào và yêu cầu mô hình tái tạo lại phần đó. Ví dụ điển hình là **Mô hình hóa Ngôn ngữ** (Language Modeling) – dự đoán từ tiếp theo trong một chuỗi [7]. Việc huấn luyện này không cần dữ liệu có nhãn, cho phép mở rộng quy mô lên hàng tỷ từ, và tạo ra các **biểu diễn ngữ cảnh** (contextual representations), trong đó vector của mỗi từ thay đổi tùy theo ngữ cảnh của nó, giải quyết triệt để bài toán đa nghĩa [7].

Mô hình nền tảng thu được sau quá trình pretraining không chỉ là một tập hợp các tham số; nó là một "trí tuệ" ngôn ngữ tổng quát, có thể được tinh chỉnh (finetune) với một lượng nhỏ dữ liệu có nhãn để đạt hiệu suất vượt trội trên vô số tác vụ khác nhau. Kết quả là một cuộc cách mạng thực sự trong NLP, với các mô hình như BERT đạt được những cải tiến đáng kể trên các bộ chuẩn đánh giá [1]. Ví dụ, BERT đã đẩy điểm số trung bình trên bộ GLUE lên 80.5% (cải thiện 7.7% tuyệt đối) và đạt điểm F1 93.2 trên SQuAD v1.1 [1]. Các mô hình hiện đại hơn như Llama 3, với 405B tham số và được huấn luyện trên 15.6 nghìn tỷ token, tiếp tục thể hiện sức mạnh vượt trội, cho thấy tiềm năng to lớn của việc mở rộng quy mô pretraining [6].

Tóm lại, pretraining đã giải quyết được những hạn chế cốt lõi của các phương pháp trước đó bằng cách:

- Tạo ra các biểu diễn từ giàu ngữ cảnh, thích ứng với từng trường hợp sử dụng.
- Cung cấp một sự khởi tạo tham số mạnh mẽ, giảm đáng kể nhu cầu về dữ liệu gán nhãn cho các tác vụ hạ nguồn.
- Cho phép các mô hình khai thác triệt để lượng dữ liệu văn bản khổng lồ và đa dạng có sẵn trên Internet.

Đây là động lực chính thúc đẩy sự phát triển của các mô hình ngôn ngữ hiện đại và sẽ được khám phá chi tiết trong các phần tiếp theo, bắt đầu với các kỹ thuật xử lý từ vệt như mô hình hóa subword.

2 Mô hình hóa Subword

Một trong những quyết định thiết kế quan trọng nhất trong các mô hình tiền huấn luyện là cách xử lý từ vựng. Thay vì sử dụng một từ vựng cố định gồm các từ hoàn chỉnh (có thể lên tới hàng trăm nghìn từ), các mô hình hiện đại thường áp dụng **mô hình hóa subword** (subword modeling) để giải quyết các vấn đề về từ hiếm, từ mới, và lỗi chính tả [7]. Phần này trình bày các phương pháp phổ biến để xây dựng từ vựng subword, từ Byte-Pair Encoding (BPE) cho đến các biến thể như WordPiece và SentencePiece, cũng như cách xử lý sự không khớp giữa subword và nhân từ trong các tác vụ như nhận dạng thực thể có tên (NER).

2.1 Vấn đề của Từ vựng Cố định

Trong các hệ thống NLP truyền thống, từ vựng được xây dựng từ tập huấn luyện và có kích thước cố định, thường là vài chục nghìn từ. Mọi từ mới xuất hiện trong quá trình kiểm tra (test time) đều bị ánh xạ vào một token đặc biệt UNK (unknown) [7]. Cách tiếp cận này có ba nhược điểm chính:

1. **Từ hiếm (rare words):** Các từ xuất hiện ít lần trong tập huấn luyện thường không được học tốt, dẫn đến biểu diễn kém chất lượng.
2. **Từ mới (out-of-vocabulary – OOV):** Các từ mới xuất hiện trong thực tế (tên riêng, từ lóng, thuật ngữ mới) không thể được xử lý một cách có ý nghĩa.
3. **Lỗi chính tả và biến thể:** Các biến thể chính tả (ví dụ: "color" và "colour") được coi là các từ hoàn toàn khác nhau, làm tăng kích thước từ vựng và giảm khả năng tổng quát hóa.

Mô hình hóa subword ra đời nhằm khắc phục những hạn chế này bằng cách chia nhỏ các từ thành các đơn vị nhỏ hơn (subword tokens), vừa đảm bảo xử lý được hầu hết các từ, vừa giữ cho kích thước từ vựng ở mức hợp lý.

2.2 Thuật toán Byte-Pair Encoding (BPE)

Byte-Pair Encoding (BPE) là một thuật toán đơn giản và hiệu quả để xây dựng từ vựng subword, ban đầu được sử dụng trong dịch máy và sau đó trở thành tiêu chuẩn trong các mô hình tiền huấn luyện [7]. Ý tưởng của BPE là bắt đầu từ tập hợp các ký tự cơ bản (bao gồm cả ký hiệu kết thúc từ) và liên tục hợp nhất cặp ký tự liên kề xuất hiện thường xuyên nhất trong ngữ liệu để tạo thành các subword mới [7]. Thuật toán gồm các bước sau:

1. Khởi tạo từ vựng với tất cả các ký tự đơn lẻ và một ký hiệu đánh dấu cuối từ.
2. Duyệt qua ngữ liệu để đếm tần suất xuất hiện của tất cả các cặp ký tự liên kề.
3. Tìm cặp xuất hiện nhiều nhất, thêm nó vào từ vựng dưới dạng một subword mới.
4. Thay thế tất cả các lần xuất hiện của cặp đó bằng subword mới trong ngữ liệu.
5. Lặp lại bước 2-4 cho đến khi đạt được kích thước từ vựng mong muốn.

Kết quả là các từ phổ biến sẽ trở thành một subword duy nhất, trong khi các từ hiếm hoặc mới sẽ được chia thành các thành phần con [7]. Ví dụ, từ "taaaasty" có thể được phân tách thành "taa" + "aaa" + "sty" nếu các subword này có trong từ vựng. Trong trường hợp xấu nhất, một từ có thể bị chia thành các ký tự riêng lẻ.

2.3 Các Thuật toán Subword Phổ biến khác

Ngoài BPE, một số thuật toán khác cũng được sử dụng rộng rãi trong các mô hình tiền huấn luyện:

- **WordPiece:** Được sử dụng trong BERT [1]. Khác với BPE, WordPiece không hợp nhất dựa trên tần suất xuất hiện của cặp, mà dựa trên việc tối đa hóa khả năng hợp lý của ngữ liệu khi thêm một subword mới. BERT sử dụng từ vựng WordPiece gồm 30.000 token [1].
- **SentencePiece Unigram LM:** Được sử dụng trong các mô hình đa ngôn ngữ như XLM-RoBERTa. SentencePiece coi văn bản là một chuỗi các ký tự và sử dụng mô hình ngôn ngữ unigram để học từ vựng subword tối ưu [?]. Phương pháp này không yêu cầu tiền xử lý dấu cách (space) và đặc biệt hiệu quả cho các ngôn ngữ không có ranh giới từ rõ ràng (như tiếng Nhật, tiếng Trung). XLM-RoBERTa sử dụng từ vựng SentencePiece với 250.000 token [?].

2.4 Thách thức khi áp dụng Subword cho Các Tác vụ Gán nhãn

Một vấn đề phát sinh khi sử dụng subword tokenization là sự không khớp giữa các token và các đơn vị từ trong dữ liệu gán nhãn. Ví dụ, trong tác vụ Nhận dạng Thực thể có Tên (NER), nhãn BIO được gán cho từng từ trong câu, nhưng mô hình lại xử lý các *subword token*. Điều này đòi hỏi hai giải pháp [?]:

1. **Trong quá trình huấn luyện:** Gán nhãn BIO của từ gốc cho tất cả các subword token con của nó. Ví dụ, với từ "Sanitas" được tách thành "San" và "##tas", cả hai token đều nhận nhãn 'I-LOC' nếu "Sanitas" là một phần của thực thể địa điểm.
2. **Trong quá trình suy luận:** Thường chỉ sử dụng nhãn dự đoán của subword token đầu tiên để gán cho toàn bộ từ, bỏ qua các thông tin từ các token còn lại. Một số phương pháp phức tạp hơn kết hợp phân phối xác suất của các subword để tìm nhãn từ tối ưu.

Tóm lại, mô hình hóa subword là một thành phần quan trọng trong kiến trúc của các mô hình tiền huấn luyện, cho phép xử lý linh hoạt các từ hiếm và mới, đồng thời giảm kích thước từ vựng. Các thuật toán như BPE, WordPiece và SentencePiece mỗi loại có những ưu điểm riêng, và việc lựa chọn phụ thuộc vào ngôn ngữ và tác vụ cụ thể. Việc hiểu rõ cách chúng hoạt động và cách giải quyết sự không khớp với nhãn từ là cần thiết để áp dụng hiệu quả các mô hình tiền huấn luyện vào thực tế.

3 Ba cách tiếp cận Pretraining Mô hình

Kiến trúc mạng nơ-ron quyết định cách thức tiền huấn luyện và các ứng dụng tự nhiên của mô hình [7]. Dựa trên kiến trúc Transformer, có ba cách tiếp cận chính để tiền huấn luyện: (1) bộ mã hóa (encoder) cho các tác vụ hiểu ngữ nghĩa, (2) bộ giải mã (decoder) cho các tác vụ sinh văn bản, và (3) kiến trúc kết hợp mã hóa-giải mã (encoder-decoder) kết hợp cả hai khả năng. Phần này sẽ trình bày chi tiết từng cách tiếp cận, từ cơ chế tiền huấn luyện, các mô hình tiêu biểu, cho đến cách tinh chỉnh cho các tác vụ hạ nguồn.

3.1 Bộ mã hóa (Encoders) – Học biểu diễn hai chiều

3.1.1 Đặc điểm và Mục tiêu Tiền huấn luyện

Bộ mã hóa Transformer sử dụng cơ chế tự chú ý không bị che giấu (unmasked self-attention), cho phép mỗi token có thể nhìn thấy toàn bộ ngữ cảnh cả bên trái và bên phải [?]. Điều này đặc biệt hữu ích cho các tác vụ phân tích và hiểu ngôn ngữ, nhưng lại gây khó khăn cho việc áp dụng mô hình hóa ngôn ngữ chuẩn (vì từ cần dự đoán có thể "nhìn thấy chính nó" thông qua ngữ cảnh hai chiều) [1]. Để giải quyết, BERT đề xuất **Masked Language Modeling (MLM)** – một dạng của bài tập điền khuyết (Cloze task) [1].

Trong MLM, một tỷ lệ ngẫu nhiên (thường là 15%) các token trong đầu vào bị che giấu, và mô hình được huấn luyện để dự đoán các token bị che giấu đó dựa trên ngữ cảnh hai chiều [7]. Để giảm sự không khớp giữa tiền huấn luyện (có token [MASK]) và tinh chỉnh (không có token [MASK]), BERT áp dụng chiến lược thay thế linh hoạt [1]:

- 80% thời gian: thay thế bằng token [MASK].
- 10% thời gian: thay thế bằng một từ ngẫu nhiên.
- 10% thời gian: giữ nguyên từ (nhưng vẫn yêu cầu dự đoán).

Ngoài MLM, BERT còn sử dụng tác vụ **Next Sentence Prediction (NSP)** để giúp mô hình hiểu mối quan hệ giữa các câu [1]. Trong NSP, 50% các cặp câu là liên tiếp nhau trong ngữ liệu (nhân IsNext) và 50% là các câu được lấy ngẫu nhiên (nhân NotNext). Token [CLS] được thêm vào đầu mỗi chuỗi để phục vụ cho cả MLM và NSP [1]. Các tác vụ này giúp BERT xây dựng biểu diễn ngữ cảnh mạnh mẽ, được thể hiện qua việc cải thiện đáng kể điểm số trên 11 tác vụ NLP [1].

3.1.2 Các mô hình và Biến thể

- **BERT:** Có hai phiên bản chính [1]: BERT-Base (12 tầng, 768 chiều ẩn, 110M tham số) và BERT-Large (24 tầng, 1024 chiều ẩn, 340M tham số). Được huấn luyện trên BooksCorpus (800M từ) và Wikipedia tiếng Anh (2.5 tỷ từ) với 64 chip TPU trong 4 ngày [7].
- **RoBERTa:** Cải tiến BERT bằng cách huấn luyện lâu hơn với nhiều dữ liệu hơn (160GB văn bản), loại bỏ NSP, sử dụng động học lớn hơn, và thay đổi chiến lược masking động [5]. Kết quả vượt trội trên nhiều bộ chuẩn, cho thấy tầm quan trọng của dữ liệu và thời gian huấn luyện [7].
- **SpanBERT:** Che giấu các đoạn văn bản liên tục (spans) thay vì các token riêng lẻ, tạo ra một tác vụ khó hơn và hữu ích hơn cho các bài toán như trả lời câu hỏi [4].

3.1.3 Tinh chỉnh (Fine-tuning)

Các mô hình encoder được tinh chỉnh bằng cách thêm một lớp đầu ra (classification head) lên trên token [CLS] (cho phân loại toàn bộ chuỗi) hoặc trên từng token (cho các tác vụ gán nhãn) [?]. Quá trình này chỉ cần một lượng nhỏ dữ liệu có nhãn và có thể thực hiện trên một GPU thông thường [7]. Các ứng dụng phổ biến bao gồm phân tích cảm xúc (SST-2), suy luận ngôn ngữ tự nhiên (MNLI), và nhận dạng thực thể có tên (NER) [?, p.14-17].

3.2 Bộ giải mã (Decoders) – Mô hình ngôn ngữ tự hồi quy

3.2.1 Đặc điểm và Mục tiêu Tiền huấn luyện

Bộ giải mã Transformer (decoder-only) sử dụng cơ chế tự chú ý nhân quả (causal self-attention), trong đó mỗi token chỉ có thể chú ý đến các token trước đó (bên trái) [?]. Đây là kiến trúc lý tưởng cho các mô hình ngôn ngữ tự hồi quy, dự đoán từ tiếp theo dựa trên lịch sử ngữ cảnh [7]. Mục tiêu tiền huấn luyện là **mô hình hóa ngôn ngữ chuẩn**:

$$p(w_t \mid w_1, \dots, w_{t-1})$$

Điều này cho phép mô hình học phân phối xác suất của ngôn ngữ một cách tự nhiên và có thể sinh văn bản mới bằng cách lấy mẫu lặp lại.

3.2.2 Các mô hình tiêu biểu

- **GPT (Generative Pre-trained Transformer):** Phiên bản đầu tiên (2018) có 12 tầng, 117M tham số, được huấn luyện trên BooksCorpus [7]. Đạt kết quả vượt trội trên các tác vụ suy luận ngôn ngữ tự nhiên [7].
- **GPT-2 (1.5B tham số):** Cho thấy khả năng sinh văn bản ấn tượng, mở ra nhận thức về tiềm năng của các mô hình ngôn ngữ lớn [7].
- **Llama 3:** Mô hình decoder-only hiện đại với 8B, 70B, và 405B tham số, được huấn luyện trên 15.6 nghìn tỷ token [6]. Sử dụng kiến trúc Transformer dày đặc (dense) với các cải tiến như Grouped Query Attention (GQA), cửa sổ ngữ cảnh 128K token, và từ vựng 128K token [6]. Llama 3 được tối ưu hóa thông qua các quy luật tỷ lệ (scaling laws) để đạt hiệu suất tối ưu với ngân sách tính toán [6].

3.2.3 Tinh chỉnh và Sử dụng

Các decoder có thể được tinh chỉnh theo hai cách:

1. **Phân loại:** Thêm một lớp tuyến tính trên trạng thái ẩn của từ cuối cùng để phân loại toàn bộ chuỗi (ví dụ: phân tích cảm xúc) [7].
2. **Sinh văn bản:** Sử dụng trực tiếp phân phối xác suất đã được tiền huấn luyện để sinh các chuỗi mới (ví dụ: dịch máy, tóm tắt, đối thoại) [7].

Một đặc điểm thú vị của các decoder cực lớn (như GPT-3 175B) là khả năng **học trong ngữ cảnh (in-context learning)**: chúng có thể thực hiện một tác vụ mới chỉ bằng cách cung cấp một vài ví

dự trong phần tiền tố (prompt), mà không cần cập nhật gradient [7]. Điều này đã cách mạng hóa cách chúng ta tương tác với các mô hình ngôn ngữ.

3.3 Kiến trúc Mã hóa-Giải mã (Encoder-Decoders)

3.3.1 Đặc điểm và Mục tiêu Tiền huấn luyện

Kiến trúc encoder-decoder kết hợp khả năng hiểu ngữ cảnh hai chiều của encoder và khả năng sinh văn bản tự hồi quy của decoder [7]. Mục tiêu tiền huấn luyện phổ biến nhất là **Span Corruption** (còn gọi là denoising), trong đó một phần của đầu vào bị loại bỏ và mô hình phải tái tạo lại phần đó [7].

Mô hình T5 (Text-to-Text Transfer Transformer) là đại diện tiêu biểu cho cách tiếp cận này. Trong T5, các đoạn văn bản có độ dài khác nhau được thay thế bằng các placeholder duy nhất (ví dụ: <X>, <Y>) ở phía encoder, và decoder được huấn luyện để sinh ra các đoạn bị loại bỏ đó [7]. Nghiên cứu của Raffel et al. (2018) chỉ ra rằng encoder-decoder với span corruption hoạt động tốt hơn so với chỉ dùng decoder hoặc chỉ dùng encoder cho nhiều tác vụ, đặc biệt là các bài toán sinh văn bản [7].

3.3.2 Ứng dụng và Đánh giá

Mô hình T5 có thể được tinh chỉnh để thực hiện nhiều tác vụ khác nhau bằng cách định dạng tất cả các bài toán dưới dạng "text-to-text": đầu vào là văn bản, đầu ra là văn bản mong muốn [7]. Điều này bao gồm dịch máy, tóm tắt, trả lời câu hỏi, và phân loại (bằng cách sinh ra nhãn). T5 đã đạt được kết quả ấn tượng trên nhiều bộ chuẩn, cho thấy tính linh hoạt và sức mạnh của kiến trúc này.

3.4 Tổng kết So sánh

Bảng dưới đây tóm tắt sự khác biệt giữa ba cách tiếp cận tiền huấn luyện:

Đặc điểm	Encoders	Decoders	Encoder-Decoders
Cơ chế chú ý	Hai chiều (bidirectional)	Nhân quả (causal)	Hai chiều (encoder) + Nhân quả (decoder)
Mục tiêu pre-training	Masked LM (MLM)	Language Modeling (LM)	Span Corruption (Denoising)
Mô hình tiêu biểu	BERT, RoBERTa, SpanBERT	GPT, Llama 3, GPT-3/4	T5
Ưu điểm chính	Hiểu ngữ cảnh sâu, tốt cho phân tích	Sinh văn bản tự nhiên, in-context learning	Kết hợp cả hai, linh hoạt
Ứng dụng	Phân loại, NER, NLI	Sinh văn bản, dịch, tóm tắt	Dịch máy, tóm tắt, QA

Như vậy, ba cách tiếp cận tiền huấn luyện phục vụ cho các mục đích khác nhau: encoder tập trung vào biểu diễn và hiểu, decoder tập trung vào sinh, và encoder-decoder kết hợp cả hai. Sự lựa chọn phụ thuộc vào tác vụ cụ thể và yêu cầu về ngữ cảnh. Các mô hình hiện đại như Llama 3 (decoder) và BERT (encoder) đã cho thấy sức mạnh vượt trội trong từng lĩnh vực, trong khi các mô hình như T5 cung cấp một giải pháp thống nhất cho nhiều bài toán khác nhau.

4 Khám phá sự thật: Pretraining đang *dạy* mô hình điều gì?

Tiền huấn luyện không chỉ đơn thuần là học cách dự đoán từ tiếp theo hay token bị che giấu; thông qua quá trình này, các mô hình ngôn ngữ lớn tích lũy một lượng tri thức khổng lồ và đa dạng về ngôn ngữ và thế giới [7]. Tuy nhiên, bên cạnh những kiến thức hữu ích, chúng cũng học và có thể khuếch

đại những định kiến xã hội có hại, đồng thời đặt ra những thách thức lớn về bản quyền và quyền riêng tư. Phần này sẽ phân tích những gì mà các mô hình tiền huấn luyện thực sự học được, những rủi ro tiềm ẩn, và các biện pháp giảm thiểu đang được áp dụng.

4.1 Những Kiến thức Ngôn ngữ và Thế giới được Học

Một mô hình ngôn ngữ được tiền huấn luyện trên văn bản quy mô lớn sẽ học được vô số các thuộc tính thống kê của ngôn ngữ, từ cú pháp, ngữ nghĩa, đến tri thức thực tế và thậm chí cả những mô hình suy luận đơn giản [7]. Các ví dụ trong bài giảng đã minh họa rõ ràng điều này:

- **Kiến thức thực tế (Trivia/Knowledge):** Mô hình có thể điền chính xác "Stanford" vào câu "*Stanford University is located in _____, California.*" [7], cho thấy nó đã ghi nhớ các sự kiện và địa danh từ dữ liệu huấn luyện.
- **Cú pháp (Syntax):** Dự đoán chính xác "a" trong "*I put ____ fork down on the table.*" [7] thể hiện sự hiểu biết về các quy tắc ngữ pháp (mạo từ đi kèm với danh từ đếm được số ít).
- **Cộng đồng tham chiếu (Coreference):** Trong câu "*The woman walked across the street, checking for traffic over ____ shoulder.*", mô hình có thể điền "her" [7], thể hiện khả năng giải quyết đại từ dựa trên ngữ cảnh và giới tính.
- **Ngữ nghĩa từ vựng và chủ đề (Lexical semantics/topic):** Với câu "*I went to the ocean to see the fish, turtles, seals, and _____.*", mô hình có thể dự đoán các từ thuộc chủ đề sinh vật biển như "whales" hoặc "dolphins" [7].
- **Cảm xúc (Sentiment):** Từ đoạn văn có chứa "the value I got from the two hours watching it was the sum total of the popcorn and the drink", mô hình có thể suy ra rằng bộ phim đã được đánh giá tiêu cực và điền "terrible" hoặc "boring" [7].
- **Suy luận (Reasoning) và Tính toán cơ bản:** Mặc dù không học được dãy Fibonacci, mô hình có thể điền "34" vào chuỗi "*1, 1, 2, 3, 5, 8, 13, 21, ____*" [7], cho thấy khả năng nhận diện mẫu và suy luận số học đơn giản.

Điều đáng chú ý là các mô hình ngôn ngữ học cách biểu diễn các khái niệm trừu tượng này một cách ngầm định, mà không cần bất kỳ sự giám sát hay gán nhãn nào cho các khía cạnh cụ thể. Đây chính là sức mạnh của việc tiền huấn luyện trên dữ liệu quy mô lớn.

4.2 Định kiến Xã hội và Rủi ro An toàn

Mặc dù học được nhiều kiến thức hữu ích, các mô hình tiền huấn luyện cũng hấp thụ và có thể khuếch đại những định kiến xã hội có trong dữ liệu huấn luyện [?]. Các nghiên cứu đã chỉ ra rằng các mô hình này có thể liên kết các từ như "doctor" với giới tính nam và "nurse" với giới tính nữ, hoặc khuếch đại các định kiến về chủng tộc và sắc tộc [?]. Điều này đặt ra những thách thức lớn về an toàn và trách nhiệm xã hội khi triển khai các mô hình này trong thực tế.

Để đối phó với những rủi ro này, các nhà phát triển đã áp dụng nhiều biện pháp khắc phục. Trong Llama 3, quy trình hậu huấn luyện (post-training) bao gồm các bước an toàn chặt chẽ [6]:

- **An toàn tiền huấn luyện:** Lọc dữ liệu để loại bỏ các trang web chứa nội dung không an toàn hoặc thông tin cá nhân (PII) [6].
- **Tinh chỉnh an toàn (Safety finetuning):** Sử dụng dữ liệu gán nhãn về an toàn để huấn luyện mô hình tránh sinh ra nội dung độc hại. Các chỉ số đo lường bao gồm Tỷ lệ vi phạm (Violation Rate - VR) và Tỷ lệ từ chối sai (False Refusal Rate - FRR), với mục tiêu cân bằng giữa an toàn và hữu ích [6].
- **Llama Guard:** Một bộ phân loại (classifier) được tinh chỉnh từ Llama 3 8B để phát hiện và lọc các đầu vào/đầu ra vi phạm các chính sách an toàn, bao gồm cả các chủ đề nhạy cảm như ngôn từ kích động thù địch, bạo lực, và nội dung khiêu dâm [6].

Những nỗ lực này đã giúp Llama 3 đạt được sự cân bằng tốt giữa việc giảm thiểu nội dung độc hại và duy trì tính hữu ích cho người dùng, cạnh tranh với các mô hình đóng hàng đầu [6].

4.3 Vấn đề Bản quyền và Quyền riêng tư

Một thách thức khác của tiền huấn luyện là việc sử dụng dữ liệu có bản quyền từ Internet. Các mô hình lớn thường được huấn luyện trên các tập dữ liệu khổng lồ như BooksCorpus (800 triệu từ sách điện tử) và Wikipedia [7]. Điều này đã dẫn đến nhiều vụ kiện pháp lý từ các tác giả, nhà xuất bản và các tổ chức báo chí, cáo buộc các công ty công nghệ vi phạm bản quyền khi sử dụng tác phẩm của họ để huấn luyện các mô hình AI sinh sản [7]. Ví dụ, New York Times đã kiện OpenAI và Microsoft vì sử dụng hàng triệu bài báo của họ để huấn luyện các chatbot cạnh tranh [7].

Bên cạnh đó, vấn đề bảo mật và quyền riêng tư cũng nổi lên như một mối quan tâm lớn. Các cuộc tấn công **Membership Inference** cho phép kẻ tấn công xác định liệu một đoạn dữ liệu cụ thể có nằm trong tập huấn luyện của mô hình hay không, dẫn đến rò rỉ thông tin nhạy cảm như địa chỉ, email hoặc thông tin cá nhân khác có trong dữ liệu web [7]. Để giảm thiểu rủi ro này, Llama 3 đã triển khai các bước lọc PII nghiêm ngặt và đánh giá mức độ ghi nhớ (memorization) của mô hình, cho thấy tỷ lệ ghi nhớ từ vựng rất thấp (1.13% với $n=50$ và 3.91% với $n=1000$) [6]. Tuy nhiên, vấn đề vẫn còn đó và đòi hỏi các giải pháp tiếp tục được phát triển.

Tóm lại, tiền huấn luyện đã mang lại những bước tiến vượt bậc cho NLP, nhưng cũng đặt ra những thách thức lớn về đạo đức, pháp lý và kỹ thuật. Việc hiểu rõ những gì mô hình thực sự học được, đồng thời phát triển các cơ chế kiểm soát và giảm thiểu rủi ro, là điều cần thiết để đảm bảo các hệ thống AI hoạt động an toàn, công bằng và có trách nhiệm.

5 Mô hình quy mô cực lớn và Học trong ngữ cảnh

Sự phát triển của các mô hình ngôn ngữ trong những năm gần đây được thúc đẩy bởi một quan sát thực nghiệm đơn giản nhưng mạnh mẽ: **việc tăng quy mô mô hình và dữ liệu sẽ dẫn đến những cải thiện đáng kể và có thể dự đoán được về hiệu suất** [7]. Từ các mô hình hàng trăm triệu tham số như BERT và GPT-1, chúng ta đã tiến tới các mô hình hàng trăm tỷ tham số như GPT-3 (175B) và Llama 3 (405B) [7]. Quá trình mở rộng này không chỉ đơn thuần là tăng kích thước; nó đã dẫn đến sự xuất hiện của các khả năng mới nổi (emergent abilities), đặc biệt là **học trong ngữ cảnh (in-context learning)** – khả năng thực hiện các tác vụ mới chỉ từ các ví dụ được cung cấp trong phần nhắc (prompt), mà không cần cập nhật gradient [7]. Phần này sẽ phân tích các quy luật mở rộng chi phối sự phát triển này, các chiến lược tối ưu để sử dụng tài nguyên tính toán, và khả năng học trong ngữ cảnh đã thay đổi cách chúng ta tương tác với các mô hình ngôn ngữ như thế nào.

5.1 Định luật Mở rộng (Scaling Laws)

Các định luật mở rộng (scaling laws) là những quan hệ toán học mô tả cách hiệu suất của mô hình thay đổi khi tăng quy mô [3]. Nghiên cứu thực nghiệm đã chỉ ra rằng khi tăng số lượng tham số, kích thước dữ liệu huấn luyện, hoặc cả hai, thì độ phức tạp (perplexity) của mô hình trên tập kiểm tra giảm một cách ổn định và có thể dự đoán được theo hàm mũ [7]. Cụ thể, mối quan hệ giữa lỗi kiểm tra (test loss) L và số lượng tham số N thường tuân theo dạng:

$$L(N) \propto N^{-\alpha}$$

với α là một hằng số dương [3]. Những quy luật này cho phép các nhà phát triển dự đoán hiệu suất của các mô hình lớn hơn trước khi đầu tư chi phí huấn luyện khổng lồ.

Llama 3 là một ví dụ điển hình cho việc áp dụng các định luật mở rộng trong thực tế. Nhóm phát triển đã xây dựng các quy luật tỷ lệ chuyên biệt để dự đoán hiệu suất trên các tác vụ phân tích hạ nguồn (downstream tasks) trước khi huấn luyện mô hình 405B tham số [6]. Bằng cách huấn luyện các mô hình nhỏ hơn với các ngân sách tính toán khác nhau (từ 6×10^{18} đến 10^{22} FLOPs), họ đã xác định được mối quan hệ giữa ngân sách tính toán và số lượng tham số tối ưu [6]. Kết quả cho thấy với ngân sách 3.8×10^{25} FLOPs, một mô hình khoảng 402B tham số với 16.55 nghìn tỷ token là tối ưu [6]. Dựa trên quan sát rằng các đường cong IsoFLOPs trở nên phẳng hơn xung quanh điểm tối ưu khi ngân sách tính toán tăng, nhóm nghiên cứu quyết định chọn mô hình 405B tham số [6].

5.2 Hiệu suất Mở rộng và Chiến lược Tối ưu

Một câu hỏi quan trọng trong việc mở rộng mô hình là: với một ngân sách tính toán cố định, nên phân bổ giữa số lượng tham số và lượng dữ liệu huấn luyện như thế nào để đạt hiệu suất tốt nhất? Nghiên cứu của Hoffmann et al. (2022) trên mô hình Chinchilla đã chỉ ra rằng nhiều mô hình lớn trước đó (như GPT-3 175B, Gopher 280B) đã được huấn luyện với quá ít dữ liệu so với kích thước của chúng [3]. Cụ thể, Chinchilla với 70B tham số được huấn luyện trên 1.4 nghìn tỷ token đã đạt hiệu suất tốt hơn các mô hình lớn hơn nhiều như GPT-3 (175B, 300B token) hay Gopher (280B, 300B token) [7]. Điều này cho thấy tầm quan trọng của việc cân bằng giữa kích thước mô hình và lượng dữ liệu.

Llama 3 đã áp dụng một chiến lược thú vị: trong khi mô hình 405B được huấn luyện với số lượng token gần như tối ưu theo quy luật mở rộng, các mô hình nhỏ hơn (8B và 70B) lại được huấn luyện lâu hơn nhiều so với mức tối ưu về mặt tính toán [6]. Điều này có nghĩa là các mô hình nhỏ hơn được huấn luyện với nhiều token hơn mức cần thiết để đạt được hiệu suất tối ưu cho ngân sách tính toán của chúng, nhưng kết quả là chúng hoạt động tốt hơn các mô hình có kích thước tối ưu về mặt tính toán khi được sử dụng trong suy luận (inference) [6]. Đây là một sự đánh đổi chiến lược: hy sinh hiệu quả huấn luyện để đạt được hiệu suất suy luận tốt hơn, điều này rất có giá trị khi chi phí suy luận là yếu tố quyết định trong triển khai thực tế.

5.3 Học trong Ngữ cảnh (In-context Learning)

Một trong những khám phá đáng chú ý nhất khi mở rộng quy mô mô hình là sự xuất hiện của khả năng **học trong ngữ cảnh** [7]. Khác với học truyền thống (cập nhật trọng số thông qua gradient descent), học trong ngữ cảnh cho phép mô hình thực hiện một tác vụ mới chỉ bằng cách cung cấp các ví dụ trong phần nhắc (prompt) [7]. Ví dụ, với prompt:

```
"thanks -> merci"  
"hello -> bonjour"  
"mint -> menthe"  
"otter -> "
```

Mô hình có thể suy ra rằng tác vụ là dịch từ tiếng Anh sang tiếng Pháp và tạo ra "loutre" [7]. Điều này cho thấy mô hình không chỉ đơn thuần là ghi nhớ các cặp từ; nó đã học được khái niệm trừu tượng về "dịch thuật" từ các ví dụ và áp dụng nó vào một từ mới chưa từng thấy trong ngữ cảnh đó.

GPT-3 là mô hình tiên phong trong việc thể hiện khả năng này ở quy mô lớn. Với 175B tham số, GPT-3 có thể thực hiện nhiều tác vụ khác nhau (dịch thuật, trả lời câu hỏi, suy luận) chỉ với một vài ví dụ trong prompt, mà không cần bất kỳ sự tinh chỉnh nào [7]. Cơ chế đằng sau hiện tượng này vẫn đang được nghiên cứu, nhưng có giả thuyết cho rằng trong quá trình tiền huấn luyện, mô hình đã học được một siêu thuật toán (meta-learning): nó học cách điều chỉnh phân phối đầu ra dựa trên ngữ cảnh, một dạng "học tập tại chỗ" không cần thay đổi tham số [7].

Tóm lại, việc mở rộng quy mô mô hình không chỉ đơn thuần là tăng kích thước; nó đã dẫn đến những thay đổi về chất trong khả năng của các mô hình ngôn ngữ. Các định luật mở rộng cung cấp một khuôn khổ để hiểu và dự đoán những thay đổi này, trong khi học trong ngữ cảnh mở ra những cách tương tác mới với các mô hình, giảm đáng kể nhu cầu về dữ liệu có nhãn và tinh chỉnh cho từng tác vụ cụ thể. Những tiến bộ này đã đặt nền móng cho sự phát triển của các hệ thống AI tổng quát hơn, có khả năng thích ứng linh hoạt với nhiều tác vụ khác nhau chỉ thông qua tương tác ngôn ngữ tự nhiên.

6 Tổng kết

Trong bài giảng này, chúng ta đã cùng nhau khám phá một trong những khái niệm quan trọng và có tác động lớn nhất đến sự phát triển của Xử lý Ngôn ngữ Tự nhiên hiện đại: **Tiền huấn luyện (Pretraining)**. Hành trình bắt đầu từ việc nhận ra những hạn chế của các biểu diễn từ tĩnh như Word2Vec hay GloVe, vốn không thể giải quyết được tính đa nghĩa của từ trong các ngữ cảnh khác

nhau [7]. Điều này đã dẫn đến sự ra đời của các biểu diễn ngữ cảnh (contextual embeddings), nơi vector của một từ thay đổi tùy theo ngữ cảnh mà nó xuất hiện, giải quyết triệt để bài toán đa nghĩa và đặt nền móng cho các mô hình ngôn ngữ hiện đại.

Chúng ta đã thấy rằng tiền huấn luyện không chỉ đơn thuần là một kỹ thuật; nó là một *sự thay đổi mô hình* (paradigm shift) trong cách xây dựng các hệ thống NLP. Thay vì xây dựng từng mô hình riêng biệt cho từng tác vụ với dữ liệu gán nhãn hạn chế, tiền huấn luyện cho phép chúng ta tạo ra các **mô hình nền tảng** (foundation models) tổng quát, có thể được tinh chỉnh (finetune) cho vô số tác vụ khác nhau với một lượng nhỏ dữ liệu có nhãn [7]. Điều này đã được chứng minh qua hiệu suất vượt trội của BERT trên 11 tác vụ NLP, bao gồm cả GLUE và SQuAD [1], và tiếp tục được khẳng định qua các mô hình như RoBERTa, SpanBERT, T5, và dòng Llama 3.

Ba cách tiếp cận tiền huấn luyện chính đã được phân tích chi tiết:

1. **Bộ mã hóa (Encoders):** Với mục tiêu Masked Language Modeling (MLM), các mô hình như BERT học được biểu diễn hai chiều mạnh mẽ, đặc biệt hiệu quả cho các tác vụ phân tích và hiểu ngôn ngữ [7].
2. **Bộ giải mã (Decoders):** Các mô hình tự hồi quy như GPT và Llama 3, được tiền huấn luyện với mục tiêu mô hình hóa ngôn ngữ chuẩn, thể hiện khả năng sinh văn bản ấn tượng và khả năng học trong ngữ cảnh (in-context learning) khi đạt đến quy mô đủ lớn [7].
3. **Kiến trúc Mã hóa-Giải mã (Encoder-Decoders):** Mô hình T5 kết hợp ưu điểm của cả hai, sử dụng span corruption để tiền huấn luyện, tạo ra một khuôn khổ thống nhất cho nhiều tác vụ khác nhau [7].

Một trong những hiểu biết quan trọng nhất từ quá trình tiền huấn luyện là các mô hình không chỉ học ngôn ngữ mà còn học được nhiều kiến thức về thế giới: từ cú pháp, ngữ nghĩa, tham chiếu, cảm xúc, cho đến suy luận và tri thức thực tế [7]. Tuy nhiên, đi kèm với đó là những thách thức đáng kể. Các mô hình cũng học và có thể khuếch đại các định kiến xã hội có hại từ dữ liệu huấn luyện, đặt ra những yêu cầu cấp thiết về an toàn và công bằng [?]. Llama 3 đã giải quyết vấn đề này thông qua các biện pháp như lọc dữ liệu, tinh chỉnh an toàn, và phát triển Llama Guard để phân loại và lọc nội dung độc hại [6].

Bên cạnh đó, vấn đề bản quyền và quyền riêng tư nổi lên như một thách thức lớn khi các mô hình được huấn luyện trên dữ liệu web bao gồm cả tác phẩm có bản quyền và thông tin cá nhân [7]. Các cuộc tấn công membership inference có thể làm rò rỉ dữ liệu nhạy cảm, đòi hỏi các giải pháp kỹ thuật và chính sách phù hợp.

Cuối cùng, chúng ta đã thảo luận về các quy luật mở rộng (scaling laws) chi phối sự phát triển của các mô hình quy mô cực lớn. Việc tăng kích thước mô hình và dữ liệu dẫn đến những cải thiện có thể dự đoán được về hiệu suất [7], nhưng cũng đòi hỏi sự cân bằng tối ưu giữa số lượng tham số và lượng dữ liệu huấn luyện [2]. Sự xuất hiện của khả năng học trong ngữ cảnh ở các mô hình cực lớn như GPT-3 và Llama 3 đã mở ra những cách tương tác mới, cho phép các mô hình thực hiện các tác vụ mới chỉ từ các ví dụ trong prompt mà không cần tinh chỉnh [7].

Như vậy, tiền huấn luyện đã đưa NLP từ kỷ nguyên của các mô hình chuyên biệt, phụ thuộc vào dữ liệu gán nhãn, sang kỷ nguyên của các mô hình nền tảng tổng quát, có khả năng thích ứng linh hoạt với nhiều tác vụ khác nhau. Những tiến bộ này đặt nền móng cho sự phát triển của các hệ thống trí tuệ nhân tạo tổng quát hơn, đồng thời đặt ra những thách thức về đạo đức, pháp lý và kỹ thuật mà cộng đồng nghiên cứu cần tiếp tục giải quyết trong tương lai.

References

- [1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186, 2019.
- [2] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, et al. Training compute-optimal large language models. *arXiv preprint*, arXiv:2203.15556, 2022.

- [3] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katie Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Jack W. Rae, Oriol Vinyals, and Laurent Sifre. Training compute-optimal large language models, 2022.
- [4] Mandar Joshi, Danqi Chen, Yinhan Liu, Daniel S. Weld, Luke Zettlemoyer, and Omer Levy. SpanBERT: Improving pre-training by representing and predicting spans. In *Transactions of the Association for Computational Linguistics (TACL)*, volume 8, pages 64–77, 2020.
- [5] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint*, arXiv:1907.11692, 2019.
- [6] AI @ Meta Llama Team. The llama 3 herd of models. *arXiv preprint*, arXiv:2407.21783, 2024.
- [7] Diyi Yang. Pretraining. Stanford University CS224N / Ling284, Lecture 7, 2026. Slide PDF.